UNIVERSIDAD PRIVADA DEL VALLE
FACULTAD DE INFORMÁTICA Y ELECTRÓNICA
CARRERA DE LICENCIATURA EN INGENIERÍA DE SISTEMAS INFORMÁTICOS

SISTEMA WEB APLICANDO EL ALGORITMO LIGHT GRADIENT BOOSTING MACHINE PARA LA OPTIMIZACIÓN DEL TIEMPO Y PRECISIÓN EN LA DETECCIÓN DE EXFILTRACIÓN DE DATOS

CASO: TIGO BUSINESS BOLIVIA

PROYECTO DE GRADO PARA OPTAR AL TÍTULO DE LICENCIATURA EN INGENIERÍA DE SISTEMAS INFORMÁTICOS

POSTULANTE: JORGE ESTEBAN MEDRANO CHACOLLA

TUTOR: ING. GONZALO ALARCON ROLDAN

La Paz – Bolivia

2026

ÍNDICE DE CONTENIDO

1 CAPITULO IMARCO INTRODUCTORIO 1

1.1 INTRODUCCIÓN 1

1.2 PLANTEAMIENTO DEL PROBLEMA 2

1.2.1 ANTECEDENTES 2

1.2.2 CONTEXTUALIZACIÓN 4

1.2.3 IDENTIFICACIÓN DEL PROBLEMA 5

1.3 FORMULACIÓN DEL PROBLEMA 7

1.4 OBJETIVOS DE LA INVESTIGACIÓN 7

1.4.1 OBJETIVO GENERAL 7

1.4.2 OBJETIVOS ESPECÍFICOS 7

1.5 JUSTIFICACIÓN 8

1.5.1 JUSTIFICACIÓN SOCIAL 8

1.5.2 JUSTIFICACIÓN TÉCNICA 8

1.5.3 JUSTIFICACIÓN ECONÓMICA 10

1.6 DELIMITACIÓN 11

1.6.1 DELIMITACIÓN ESPACIAL 11

1.6.2 DELIMITACIÓN TEMPORAL 11

1.6.3 DELIMITACIÓN POBLACIONAL 11

1.6.4 DELIMITACIÓN TEMÁTICA 11

1.7 ALCANCES Y LÍMITES 12

1.7.1 ALCANCES 12

1.7.2 LÍMITES 13

1.8 METODOLOGÍA 13

1.8.1 ENFOQUE DE LA INVESTIGACIÓN 13

1.8.2 MÉTODO DE LA INVESTIGACIÓN 14

1.8.3 TIPO DE INVESTIGACIÓN 14

1.8.4 OPERACIONALIZACIÓN DE VARIABLES 15
1.8.5 DISEÑO DE INVESTIGACIÓN 19
1.8.6 POBLACIÓN 20
1.8.7 MUESTRA 20
2 CAPITULO IIMARCO TEÓRICO 23
2.1 MARCO TEÓRICO 23
2.1.1 INGENIERIA DE SOFTWARE 23
2.1.2 MODELOS DE DESARROLLO 27
2.1.3 ARQUITECTURA DE SISTEMA 31
2.1.4 LENGUAJE UNIFICADO DE MODELADO UML 33
2.1.5 METODOLOGÍA DE DESARROLLO DE SOFTWARE 40
2.1.6 METODOLOGÍA DE DESARROLLO DE MODELO DE IA 42
2.1.7 HERRAMIENTAS DE DESARROLLO 43
2.1.8 ESTIMACIÓN DE COSTOS 49
2.1.9 ASEGURAMIENTO DE CALIDAD 51
2.1.10 SEGURIDAD DEL SISTEMA 54
2.2 MARCO CONCEPTUAL 57
2.2.1 INTELIGENCIA ARTIFICIAL 57
2.2.2 DEFINICIÓN DE MACHINE LEARNING 57
2.2.3 APRENDIZAJE PROFUNDO 58
2.2.4 TIPOS DE APRENDIZAJE AUTOMÁTICO 58
2.2.5 GRADIENT BOOSTING MACHINE 59
2.2.6 LIGHT GRADIENT BOOSTING MACHINE 60
2.3 MARCO INSTITUCIONAL 64
2.3.1 ANTECEDENTES DE LA INSTITUCIÓN 64
2.3.2 ESTRUCTURA ORGANIZACIONAL 66
2.3.3 DESCRIPCIÓN DEL ÁREA DE ESTUDIO 66

2.3.4 INFRAESTRUCTURA TECNOLÓGICA ACTUAL 68

2.3.5 ARQUITECTURA DE RED Y SISTEMAS DE INFORMACIÓN EXISTENTES 68

2.4 MARCO NORMATIVO..... 69

2.4.1 NORMATIVA INTERNA (TIGO - TELECEL S.A.) 69

2.4.2 NORMATIVA NACIONAL (BOLIVIA)..... 70

2.4.3 ESTÁNDARES INTERNACIONALES..... **Error! Bookmark not defined.**

2.4.4 OTROS MARCOS DE REFERENCIA Y BUENAS PRÁCTICAS**Error! Bookmark not defined.**

2.5 ESTADO DEL ARTE..... 71

2.5.1 REVISIÓN Y COMPARACIÓN DE PROYECTOS NACIONALES..... 71

2.5.2 REVISIÓN Y COMPARACIÓN DE PROYECTOS INTERNACIONALES 73

3 BIBLIOGRAFÍA..... 1

4 APÉNDICES..... 1

5 ANEXOS..... 1

ÍNDICE DE CUADROS

Cuadro 1.1 Operacionalización de Variables 15

ÍNDICE DE FIGURAS

Figura 1.1 Diagrama Ishikawa 7
Figura 2.1 Ciclo de Vida del Software 27
Figura 2.2 Esquema del Modelo en Cascada 28
Figura 2.3 Esquema del Modelo Incremental 29
Figura 2.4 Esquema de Modelo Evolutivo 30
Figura 2.5 Esquema del Modelo Espiral 31
Figura 2.6 Tipos de Diagramas UML 34
Figura 2.7 Diagrama de Casos de Uso 35
Figura 2.8 Diagrama de Secuencias 36
Figura 2.9 Notación en un diagrama de clases 37
Figura 2.10 Diagrama de Actividades 38
Figura 2.11 Diagrama de Despliegue 39
Figura 2.12 Esquema de la Metodología Scrum 40
Figura 2.13 Arquitectura Algoritmo LightGBM 61

CAPITULO I

MARCO INTRODUCTORIO

CAPITULO I
MARCO INTRODUCTORIO

1.1 INTRODUCCIÓN

En la actualidad, la transformación digital ha impulsado a las empresas de telecomunicaciones a gestionar volúmenes de datos sin precedentes, convirtiéndolas en objetivos primarios para el cibercrimen organizado. La seguridad de la información ya no se limita a la protección del perímetro, sino que exige una vigilancia constante sobre el flujo de salida de los activos digitales. La exfiltración de datos, entendida como la transferencia no autorizada de información sensible, representa una de las amenazas más críticas para la infraestructura de red en Bolivia, debido a su naturaleza sigilosa y difícil de identificar mediante herramientas convencionales.

El panorama de amenazas ha evolucionado hacia ataques de quinta generación (Gen V, caracterizados por ser ciberataques a gran escala, multivectoriales y de rápida propagación), los cuales utilizan técnicas de evasión altamente sofisticadas para burlar los Sistemas de Detección de Intrusos (IDS) y de Prevención de Pérdida de Datos (DLP). Estos sistemas tradicionales, basados mayoritariamente en firmas estáticas, muestran una incapacidad creciente para identificar patrones de tráfico dinámicos. En el contexto objeto de estudio en Tigo Bolivia, resulta necesario determinar si las capacidades actuales de detección presentan limitaciones relacionadas con una latencia reactiva que compromete la integridad operativa de su Centro de Operaciones de Seguridad (SOC, por sus siglas en inglés), el área responsable de monitorear, detectar y responder a incidentes de ciberseguridad en la organización.

La inteligencia artificial surge como la respuesta técnica necesaria para cerrar la brecha de visibilidad en la red. El uso de algoritmos de Machine Learning permite analizar el comportamiento del tráfico de red en lugar de buscar únicamente coincidencias con firmas conocidas. De entre estas tecnologías, el algoritmo Light Gradient Boosting Machine (LightGBM), un marco de trabajo de aprendizaje automático basado en árboles de decisión diseñado para ser altamente eficiente destaca por su eficiencia en el procesamiento de grandes conjuntos de datos y su bajo consumo de recursos computacionales, características vitales para una empresa de gran escala como Tigo Business Bolivia.

El presente proyecto propone el desarrollo de un sistema web que utilice el algoritmo de gradiente incrementado LightGBM para optimizar la detección de exfiltración. Esta solución busca transformar la postura de seguridad de la organización de una meramente reactiva a

una proactiva. Al implementar un modelo capaz de aprender de los patrones de red habituales, se pretende identificar desviaciones que sugieran el robo de información antes de que el daño sea irreversible.

La integración de este modelo predictivo en una plataforma web facilitará la toma de decisiones por parte de los analistas de seguridad. El sistema proporcionará visualizaciones claras de las anomalías detectadas, permitiendo priorizar aquellas alertas que representan un riesgo real de compromiso de datos. Esto aborda directamente el problema de la saturación analítica causada por el exceso de falsos positivos en las herramientas actuales.

Desde una perspectiva institucional, la implementación de esta tecnología en Tigo Bolivia representa un avance significativo en la soberanía tecnológica y la protección de infraestructuras críticas nacionales. Al optimizar los tiempos de detección (conocido en la industria como MTTD o *Mean Time To Detect*, que indica el tiempo promedio que tarda una organización en descubrir una brecha de seguridad), se obtiene una mayor resiliencia ante ataques sofisticados como las Amenazas Persistentes Avanzadas (APT) y el Ransomware. Este esfuerzo se alinea con las mejores prácticas globales en ciberseguridad industrial.

1.2 PLANTEAMIENTO DEL PROBLEMA

1.2.1 ANTECEDENTES

En el contexto global, la transición hacia infraestructuras Redes Definidas por Software (SDN) permite una gestión dinámica de recursos, pero a su vez demanda la implementación de analítica de seguridad y respuesta automática (SAAR) para mitigar amenazas que los firewalls convencionales no pueden procesar eficientemente (International Telecommunication Union [ITU], 2025). Esta vulnerabilidad estructural se agrava ante un cambio fundamental en el panorama de amenazas, donde la integración de la inteligencia artificial y la automatización ha acelerado la escala de los ataques, transformando el ransomware en una economía de extorsión impulsada estrictamente por los datos (Check Point, 2026). En este escenario, el despliegue de arquitecturas de seguridad que protejan el plano de control y los dispositivos de borde resulta imperativo, dado que estos últimos son utilizados cada vez más como puntos de lanzamiento para tácticas de exfiltración que buscan vulnerar la integridad del núcleo estratégico del negocio

A nivel regional, en América, el sector de las telecomunicaciones atraviesa una etapa de transición tecnológica crítica frente a un incremento exponencial en la sofisticación del cibercrimen. Esta vulnerabilidad se ve intensificada por una saturación operativa sin precedentes; de acuerdo con el Nokia Threat Intelligence Report (2024), el tráfico malicioso

de denegación de servicio creció un 166% en el último año, lo que ha elevado la frecuencia de incidentes en las redes de las operadoras de apenas un par de eventos diarios a más de 100 ataques por día. Esta escala en la automatización de las amenazas obliga a las empresas a migrar hacia Centros de Operaciones de Seguridad basados en analítica proactiva y detección extendida para mitigar ataques complejos que los sistemas tradicionales no logran procesar. Según ESET (2024), este panorama se refleja en que el "30% de las organizaciones sufrió al menos un incidente de seguridad en 2023" (p. 5), destacando una alarmante economía de extorsión impulsada por los datos donde el "23% de las empresas fue blanco de al menos un intento de ataque de ransomware en los últimos dos años" (ESET, 2024, p. 15), confirmando que "el ransomware continuó siendo una amenaza muy activa a nivel global y también a nivel regional en América Latina durante 2023" (ESET, 2024, p. 17).

Descendiendo al ámbito nacional, en Bolivia, "La penetración del servicio de internet móvil a diciembre de 2024, alcanzó el 99%; es decir que, por cada 100 habitantes, se tienen 99 líneas activas con el servicio de internet móvil" (Autoridad de Regulación y Fiscalización de Telecomunicaciones y Transportes [ATT], 2025, p. 8). A pesar de contar con sistemas de monitoreo, el país enfrenta una "Es una actividad delictiva realizada a través de internet y tecnologías digitales con el objetivo de obtener ganancias ilegales o causar daño a las Entidades Financieras (EF) u otras organizaciones, sustrayendo información estratégica" (Autoridad de Supervisión del Sistema Financiero [ASFI], 2025, p. 2).

La urgencia de modernizar las capacidades de detección en los proveedores locales se fundamenta en los datos del Computer Security Incident Response Team (CSIRT) Bolivia (2025), donde se reporta que el 93.8% de los incidentes gestionados pertenecen a la categoría de Compromiso de la Información. Este dato es crítico, ya que el informe destaca que una de las deficiencias más recurrentes en la infraestructura nacional es el "El registro y monitoreo insuficiente, junto a la falta de respuesta ante incidentes permite a los atacantes mantener el ataque en el tiempo, pivotear a otros sistemas y manipular, extraer o destruir datos" (p. 14). Además, se identifica que el 28.6% de las vulnerabilidades corresponden a Configuraciones de Seguridad Incorrectas.

En el caso específico de Tigo Business Bolivia (Telecel S.A.), la escala de su infraestructura regional genera un volumen de tráfico que plantea desafíos operativos; de acuerdo con el levantamiento de información preliminar realizado al personal del SOC, esto puede desbordar las capacidades de inspección tradicionales, véase Apéndice 1. Según el reporte

Millicom (2024), la organización enfrenta una amenaza constante donde la sofisticación de los ataques dirigidos a la sustracción de datos' obliga a una revisión de sus protocolos de respuesta (Millicom, 2024). Esta necesidad se vuelve crítica al considerar que, en el sector de telecomunicaciones, la latencia en la detección permite que el 35.5% de las brechas de datos se ejecuten a través de vulnerabilidades (SecurityScorecard, 2025). Por consiguiente, la estrategia corporativa de Millicom para 2025 prioriza la automatización de la detección para mitigar el riesgo de exfiltración, validando la implementación de modelos de aprendizaje automático que puedan procesar de manera proactiva los patrones anómalos que los umbrales estáticos actuales no logran identificar con precisión.

1.2.2 CONTEXTUALIZACIÓN

En un ecosistema de telecomunicaciones cada vez más impulsado por la convergencia de servicios y el flujo masivo de activos digitales, las operadoras enfrentan el reto crítico de modernizar sus arquitecturas de seguridad mediante soluciones inteligentes. La digitalización acelerada y el volumen exponencial de datos que transitan por el Core de red se han vuelto fundamentales no solo para la operatividad del negocio, sino también para garantizar la confianza del cliente, evaluar la integridad de las conexiones y responder con agilidad a las amenazas del entorno. En este escenario, la capacidad de respuesta en tiempo real y la analítica predictiva emergen como componentes clave para fortalecer la resiliencia institucional en empresas comprometidas con la protección de la información.

De acuerdo al levantamiento de información preliminar realizado mediante entrevista al personal del área, véase Apéndice 1, en la actualidad, Tigo Business Bolivia enfrenta una gestión de la seguridad y detección de incidentes altamente fragmentada. Se evidenció que los sistemas de detección de intrusiones (IDS) y prevención de pérdida de datos (DLP) vigentes operan bajo arquitecturas tradicionales que dependen de reglas estáticas y firmas predefinidas, lo que dificulta el seguimiento y la identificación de patrones de exfiltración dinámicos. La recopilación y el análisis de registros (logs) se realizan de forma secuencial frente a volúmenes masivos de tráfico, lo que no solo ralentiza la capacidad de alerta, sino que también hace al sistema susceptible a omisiones críticas y al éxito de fugas de información antes de cualquier intervención manual.

Esta situación ha generado una desconexión operativa entre la ejecución de una amenaza y su contención efectiva. Por ejemplo, el Centro de Operaciones de Seguridad (SOC) carece de reportes y visibilidad en tiempo real sobre anomalías sutiles en datos cifrados, mientras que las herramientas actuales, pese a capturar eventos, terminan generando una saturación

de falsos positivos que dilata el tiempo de respuesta o directamente oculta ataques reales. Además, al tratarse de técnicas de bajo volumen y alta persistencia (low and slow), la trazabilidad del incidente se ve seriamente afectada, ya que no existe un sistema que integre de manera coherente la correlación de variables complejas con los registros de tráfico institucionales.

El crecimiento continuo de la infraestructura de Tigo Business, junto con la sofisticación de vectores de ataque como el Ransomware y el DNS Tunneling, hace evidente la necesidad de una herramienta o sistema, una solución tecnológica avanzada impulsada por el algoritmo LightGBM. Este sistema debe ser capaz de centralizar el análisis de flujos mediante el procesamiento de gradientes incrementales, optimizar los tiempos de detección y servir como base para una defensa proactiva basada en datos confiables y actualizados, minimizando así el impacto de posibles brechas de seguridad.

1.2.3 IDENTIFICACIÓN DEL PROBLEMA

En el ecosistema tecnológico de Tigo Business Bolivia, se buscará verificar si el desafío crítico en la detección temprana de exfiltración de información podría estar ocurriendo debido a una posible desactualización técnica de los sistemas IDS y DLP frente a vectores de ataque de alta complejidad. Esta brecha de seguridad genera una dependencia de procesos de inspección manuales y una visibilidad fragmentada de los eventos de red, lo que degrada la capacidad de respuesta ante incidentes en tiempo real. Es por ello que no solo se compromete la confidencialidad de millones de registros, sino que también restringe la capacidad de los analistas de seguridad para ejecutar defensas basadas en inteligencia de datos, derivando en un ciclo de protección puramente reactivo. La raíz de esta vulnerabilidad no es un evento aislado, sino la convergencia de múltiples deficiencias estructurales.

Como eje de conflicto inicial, la arquitectura de gestión de datos actual presenta una visibilidad limitada como efecto de la opacidad del tráfico cifrado y a la dispersión de registros en nodos de red heterogéneos. La falta de una estructura de datos cohesiva obliga a un procesamiento secuencial de registros (logs), lo que genera un retraso significativo entre el inicio de una fuga y su identificación. Esta latencia no permite obtener una visión holística del comportamiento de la red, transformando el análisis de seguridad en una tarea forense posterior al daño, en lugar de una supervisión dinámica y preventiva.

Desde otro punto de vista, los protocolos de medición y monitoreo revelan una asincronía en el flujo de alertas. El Tiempo Medio de Detección (MTTD) en el sector de

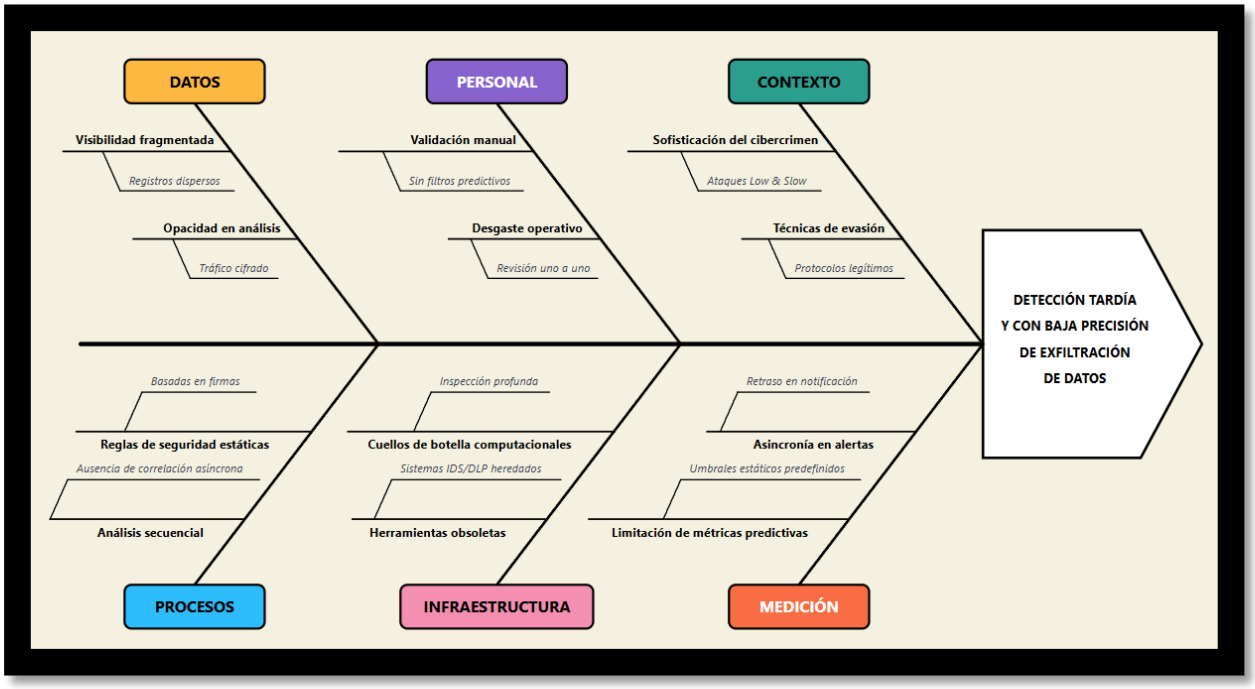
telecomunicaciones boliviano se ve afectado por el uso de firmas estáticas que fallan ante ataques polimórficos. Esto permite que la información sensible traspase el perímetro de seguridad mucho antes de que los sistemas de control emitan una notificación, además se puede observar una infraestructura heredada que no logra escalar al ritmo de las demandas de tráfico actuales de un operador convergente.

Por otra parte, el factor humano y operativo se encuentra bajo una saturación analítica constante. La imprecisión de las herramientas vigentes genera un volumen masivo de falsos positivos que desborda al SOC, obligando a los expertos a realizar validaciones manuales. Este desgaste operativo ocasiona que amenazas sutiles, como el DNS Tunneling o el Ransomware de baja intensidad, pasen desapercibidas bajo el ruido de fondo, limitando el talento técnico a tareas repetitivas en lugar de labores estratégicas de mitigación.

Así mismo, el entorno tecnológico enfrenta una barrera de escalabilidad debido a la intensidad computacional que requieren los modelos de inspección profunda convencionales. La carga sobre la memoria y el procesamiento de los servidores actuales genera cuellos de botella que ponen en riesgo la Calidad de Servicio, creando una desconexión entre la necesidad de una defensa robusta y la estabilidad de la red. En conjunto, estos factores establecen una brecha tecnológica con las herramientas actuales, resultando en un sistema de detección lento, ineficiente y vulnerable ante el cibercrimen moderno.

Tal como se puede observar en la Figura 1.1, la identificación de estos vértices permite comprender cómo la interacción entre los Datos, el Personal, la Infraestructura y los Métodos de Medición culmina en el problema central: un tiempo de detección de vulnerabilidades que requiere una transición urgente hacia arquitecturas de alto rendimiento y baja latencia.

Figura 1.1 Diagrama Ishikawa



Fuente. Elaboración Propia, 2026.

1.3 FORMULACIÓN DEL PROBLEMA

¿Cómo optimizar el tiempo y la precisión en la detección de exfiltración de datos en la infraestructura de red de la empresa de telecomunicaciones Tigo Business Bolivia?

1.4 OBJETIVOS DE LA INVESTIGACIÓN

1.4.1 OBJETIVO GENERAL

Desarrollar un sistema web aplicando el algoritmo Light Gradient Boosting Machine para la optimización del tiempo y precisión en la detección de exfiltración de datos en la empresa de telecomunicaciones Tigo Business Bolivia.

1.4.2 OBJETIVOS ESPECÍFICOS

- Determinar los controles técnicos, procedimentales y los registros disponibles actuales para la detección de exfiltración mediante el análisis de brechas en la infraestructura de Tigo Business Bolivia, para establecer una línea base de las vulnerabilidades.
- Explicar los fundamentos teóricos, conceptuales y el estado del arte referentes a la detección de anomalías en ciberseguridad y los algoritmos de Gradient Boosting, para sustentar científicamente el desarrollo de la investigación.

- Determinar el modelo de detección basado en Gradient Boosting mediante la evaluación del rendimiento, velocidad de respuesta y precisión, contrastando algoritmos como XGBoost, CatBoost y LightGBM, con el fin de seleccionar la arquitectura más apropiada para la infraestructura.
- Validar la precisión del sistema de detección de exfiltración mediante la evaluación del Tiempo Medio de Detección (MTTD) la tasa de falsos positivos y el puntaje F1 utilizando un dataset etiquetado, para asegurar la fiabilidad y consistencia de los resultados.

1.5 JUSTIFICACIÓN

1.5.1 JUSTIFICACIÓN SOCIAL

La implementación de este sistema resolverá una problemática organizacional crítica al fortalecer al Centro de Operaciones de Seguridad (SOC) de Tigo Business Bolivia. Al brindar apoyo directo a los analistas mediante la optimización de la detección temprana de amenazas, se asegura la continuidad de los servicios y se reduce la exposición de los activos digitales. En consecuencia, se eleva el estándar de protección de la información de los usuarios finales, garantizando indirectamente un ecosistema digital más seguro para la sociedad boliviana.

De este modo, la transparencia en la detección y prevención de exfiltración de datos nos permite reducir la vulnerabilidad ante fraudes y extorsiones, apoyando tanto a la parte estratégica de ciberseguridad como ser el SOC (Security Operations Center) y la gerencia de Tigo Business, como a los usuarios finales para que puedan operar en un entorno digital íntegro. Con esto logramos un mayor acercamiento debido a que se podrá interactuar en un entorno seguro, obteniendo datos en el proceso útiles para que las telecomunicaciones puedan ajustarse a las necesidades de protección y desarrollo de la sociedad boliviana en general.

1.5.2 JUSTIFICACIÓN TÉCNICA

El proyecto se justifica por la viabilidad de integrar el algoritmo LightGBM en la infraestructura actual de Tigo Business Bolivia, la cual cuenta con los servidores y el volumen masivo de registros necesarios para el entrenamiento. La solución basa su eficacia en este algoritmo de gradientes incrementales por su bajo consumo de memoria y alta capacidad para clasificar características de red desbalanceadas. Al ejecutar el motor predictivo sobre lenguajes seguros de bajo nivel, se elimina la latencia tradicional (GIL), permitiendo que la IA evalúe amenazas polimórficas de manera asíncrona y en tiempo real.

Desde el punto de vista técnico, el sistema propone una solución integral basada en una arquitectura de alto rendimiento para centralizar el análisis de tráfico de red en un entorno unificado, optimizando la gestión de incidentes y la visibilidad proactiva. Gracias a la automatización de la detección mediante el algoritmo LightGBM implementado en un ecosistema de seguridad de memoria total, se superarán las limitaciones de latencia de las herramientas genéricas interpretadas, permitiendo generar reportes forenses con una velocidad de procesamiento nativa. Aprovechando la infraestructura de la universidad y su capacidad de cómputo en centros de datos distribuidos, el proyecto presenta una fuerte viabilidad para entornos de misión crítica.

Si bien Python representa el estándar actual en la industria del Machine Learning, sus limitaciones de concurrencia impuestas por el Global Interpreter Lock (GIL) generan latencias durante el análisis de tráfico asíncrono. De acuerdo con Muñoz Guerrero (2024), en el procesamiento de modelos predictivos, las arquitecturas fundamentadas en Rust logran reducir el consumo de memoria en hasta un 40% y procesar ráfagas de datos con una latencia significativamente menor en comparación con aplicaciones equivalentes en Python. Por ello, el uso de Rust garantiza un control profundo del hardware y seguridad de memoria, eliminando las pausas imprevistas durante la ingesta de registros.

Para cumplir estos objetivos, se utilizarán las siguientes tecnologías clave:

- **Axum:** Framework backend moderno construido sobre la infraestructura asincrónica de Tokio, diseñado para manejar miles de conexiones simultáneas y procesar alertas de exfiltración con baja latencia.
- **Leptos**: Framework FrontEnd basado en WebAssembly, implementado para cubrir el requerimiento de una interfaz ágil que permita a los analistas visualizar datos sin recargas que afecten el tiempo de respuesta.
- **Polars**: Motor de análisis de datos, elegido por la necesidad de extraer características y preprocesar registros masivos de red eliminando cuellos de botella.
- LightGBM: Motor de inteligencia artificial, seleccionado para resolver la necesidad técnica de clasificar el tráfico anómalo con alta precisión, adaptándose a conjuntos de datos altamente desbalanceados.
- **PostgreSQL**: Sistema de bases de datos relacional, necesario para cumplir con el requerimiento de almacenamiento estructurado, garantizando la auditoría y trazabilidad histórica de incidentes.

- **Trunk**: Herramienta de construcción, requerida funcionalmente para el empaquetado y la integración nativa del motor web en Rust.

El motor algorítmico LightGBM funcionará como el núcleo analítico de la arquitectura. Los registros de red serán preprocesados en microsegundos para extraer sus características, las cuales alimentarán directamente al modelo de Machine Learning. Una vez que el algoritmo LightGBM clasifique un patrón como exfiltración de datos, el backend interceptará la predicción, registrará el incidente en la base de datos relacional y emitirá una notificación automatizada hacia el panel de control (frontend), cerrando el flujo operativo entre la ingesta de datos, la IA y la interfaz de usuario.

1.5.3 JUSTIFICACIÓN ECONÓMICA

Económicamente, el proyecto busca mitigar las pérdidas financieras masivas derivadas de una brecha de datos exitosa dentro de la infraestructura de Tigo Business Bolivia. A nivel global, el tiempo promedio para identificar el ciclo de vida de una filtración es de 207 días en el sector (IBM, 2025), lo que conlleva costos elevados si se considera que el costo promedio de una filtración de datos ha alcanzado los USD 4.88 millones (IBM, 2025). Estos gastos incluyen multas regulatorias, recuperación forense y compensación a usuarios, además del daño irreparable a la valoración de mercado.

A nivel operativo interno, al optimizar el Tiempo Medio de Detección (MTTD) del sistema local mediante la arquitectura de alto rendimiento propuesta, se busca evitar que se alcancen dichos ciclos prolongados de exposición. Según IBM (2025), las organizaciones que utilizan IA y automatización de seguridad ahorran un promedio de USD 2.22 millones en costos de brechas y logran reducir el ciclo de vida de la amenaza en casi 100 días. La reducción de hasta un 45% de falsos positivos permite que Por otra parte, la potencial reducción de falsos positivos estimada en hasta un 45% mediante herramientas de IA según la misma fuente permitiría que el personal del SOC enfoque sus horas-hombre en amenazas reales, lo que podría contribuir a reducir costos asociados al procesamiento de alertas y a la atención de incidentes.

Finalmente, al desarrollar una solución soberana, se aborda un riesgo crítico de la industria: el 35.5% de todas las brechas de datos en 2024 se originaron en compromisos de terceros, un incremento del 6.5% interanual (SecurityScorecard, 2025). Al reducir la dependencia de software licenciado externo y sus costos recurrentes, se garantiza una gestión de recursos más coherente y se minimiza la exposición a vulnerabilidades de la cadena de suministro.

En conjunto, estos factores garantizan una mejora económica sostenible al blindar los activos digitales de la empresa frente a pérdidas financieras catastróficas.

1.6 DELIMITACIÓN

1.6.1 DELIMITACIÓN ESPACIAL

La delimitación espacial del proyecto comprende dos perativos definidos. El contexto de estudio y la fuente de datos corresponden al Centro de Operaciones de Seguridad (SOC) de Tigo Business Bolivia, focalizando los esfuerzos en el análisis de los flujos de tráfico originados en sus centros de datos de las ciudades de La Paz y Santa Cruz. Aunque el caso de estudio se centra en los activos digitales y nodos de red de esta unidad, la implementación técnica, el entrenamiento del modelo y las fases de validación del motor de detección se llevarán a cabo en un entorno experimental controlado. Esto con la finalidad de garantizar la integridad de los sistemas en producción de la empresa durante todo el ciclo de desarrollo.

1.6.2 DELIMITACIÓN TEMPORAL

La investigación tendrá una duración de diez meses, comprendidos entre febrero de 2026 y noviembre de 2026. Este periodo incluye las fases de recolección de datos, entrenamiento del modelo, desarrollo del sistema web y la fase final de pruebas y evaluación de resultados.

1.6.3 DELIMITACIÓN POBLACIONAL

La delimitación poblacional del proyecto diferencia dos dimensiones operativas. Por un lado, la unidad de análisis de datos que evaluará el modelo LightGBM se delimita al tráfico de red saliente y los registros de logs generados por dispositivos críticos como firewalls, sistemas IDS y servidores DNS de Tigo Business Bolivia. Por otro lado, la población de usuarios se delimita a los analistas de seguridad del SOC, quienes no forman parte de los datos a clasificar, sino que fungirán exclusivamente como actores/informantes para evaluar la eficacia del sistema en entornos de misión crítica y participarán en la evaluación de la interfaz de toma de decisiones.

1.6.4 DELIMITACIÓN TEMÁTICA

El sistema propuesto se fundamenta en conceptos avanzados de ciberseguridad industrial, procesamiento de datos de alto rendimiento, detección de anomalías y toma de decisiones basada en inteligencia de datos. Estos elementos son esenciales para transformar la postura de seguridad de la organización de un esquema reactivo a uno proactivo.

- **Detección de Anomalías por Comportamiento:** Implica el análisis de patrones de tráfico dinámicos para identificar desviaciones sutiles que sugieran el robo de información, superando la rigidez de los sistemas basados en firmas estáticas.
- **Gradiente Incrementado (LightGBM):** Se centra en la aplicación de algoritmos de aprendizaje automático para el procesamiento eficiente de grandes conjuntos de datos desbalanceados, garantizando precisión en la clasificación de amenazas con un bajo consumo de recursos.
- **Arquitecturas de Alto Rendimiento:** Busca consolidar el análisis de flujos masivos mediante el uso de lenguajes de programación de sistemas, mejorando la escalabilidad y eliminando cuellos de botella en el procesamiento de registros en tiempo real.
- **Prevención de Fuga de Información:** Implica el uso de inteligencia predictiva para reducir el ciclo de vida de las amenazas, limitando su alcance de manera estricta a la detección de la fase de exfiltración de datos. El sistema no intentará identificar malwares específicos (como ransomware), vectores de infección inicial ni anomalías de red genéricas, focalizándose única y exclusivamente
- **Exfiltración de Datos:** Consiste en la transferencia no autorizada de información sensible hacia dominios externos, ejecutada de manera sigilosa mediante la manipulación de protocolos legítimos. Este fenómeno representa el objetivo final de ataques sofisticados, donde el atacante extrae activos digitales evadiendo los controles perimetrales.

El diseño del motor de detección considerará los recursos tecnológicos de los servidores de la empresa, así como la infraestructura de cómputo distribuida de la universidad para las fases de validación técnica. Al integrar estos pilares, se busca desarrollar una solución tecnológica que optimice la respuesta ante incidentes mediante el uso efectivo de la analítica avanzada.

1.7 ALCANCES Y LÍMITES

1.7.1 ALCANCES

- El sistema permitirá la ingesta y el procesamiento asíncrono masivo de registros de red de forma centralizada optimizando la extracción de características mediante el motor de Polars.
- El sistema analizará en tiempo real el flujo continuo de registros de red haciendo uso del algoritmo LightGBM el cual será entrenado y validado previamente utilizando el

tráfico histórico, clasificando el tráfico legítimo de los patrones anómalos vinculados con la exfiltración de datos.

- El sistema proporcionara un panel de control accesible desde variedad de navegadores web a personas autorizadas, mostrando alertas críticas, métricas de riesgo y el estado de la seguridad actual.
- El sistema almacenará y administrará un registro histórico estructurado de los incidentes detectados en una base de datos relacional (PostgreSQL), garantizando la trazabilidad y la consulta de eventos previos para análisis forenses.
- El sistema generará y emitirá alertas y notificaciones tempranas en tiempo real hacia el panel de control del SOC, detallando el nivel de criticidad y las características de las anomalías detectadas para facilitar la toma de decisiones del personal autorizado.

1.7.2 LÍMITES

- El sistema se limitará a la detección y notificación de incidentes; no ejecutará acciones de mitigación o bloqueo automático de tráfico en la red de producción de Tigo Business. Esto garantiza que la disponibilidad de los servicios de telecomunicaciones no se vea comprometida por potenciales falsos positivos.
- La investigación se circunscribe específicamente a la detección de la fuga de datos. Por lo tanto, no contempla el análisis ni la defensa ante otras etapas de una cadena de ataque (*Cyber Kill Chain*), tales como la explotación de vulnerabilidades iniciales o el movimiento lateral dentro de la red.
- La precisión y efectividad del motor de detección están sujetas a la integridad, volumen y continuidad de los registros proporcionados por la infraestructura existente en la empresa de telecomunicaciones.
- El despliegue y acceso al panel de control del sistema web estará restringido exclusivamente a la red interna (Intranet) del Centro de Operaciones de Seguridad (SOC), por lo que no será accesible desde internet público.

1.8 METODOLOGÍA

1.8.1 ENFOQUE DE LA INVESTIGACIÓN

El enfoque seleccionado para la investigación es el cuantitativo, donde Reyez y Reyes, (2024) nos dicen que “Este se basa en la idea de que el conocimiento se puede obtener a

través de la observación y la medición objetivas. También considera que la realidad es una sola, existe externamente y debe descubrirse y conocerse" (p. 125).

Con este enfoque podemos analizar el problema de la exfiltración de datos mediante la reelección de datos como ser el volumen de registros, tasa de falsos positivos, y la comparación entre los tiempos de detección actuales frente a la versión optimizada con el algoritmo LightGBM.

1.8.2 MÉTODO DE LA INVESTIGACIÓN

Se empleará el método analítico-deductivo, el cual se ejecutará en dos fases integradas:

- Fase Analítica: Ñaupas et al. (2023) señala que "Consiste en desagregar un todo, un sistema, en sus elementos únicos" (p. 120). En esta fase se desglosará el problema general mediante la selección de datos, la preparación y la extracción de características (features) del tráfico de red, analizando las variables clave que componen un evento de exfiltración.
- Fase Deductiva: Como nos dice Ñaupas et al. (2023), es el "Análisis de lo general (leyes, axiomas, postulados, teoremas) a casos particulares" (p. 119). Se aplicará durante la evaluación y operación del modelo entrenado LightGBM: a partir de las reglas matemáticas generales de clasificación aprendidas durante la fase de entrenamiento y validación, el algoritmo deducirá si un flujo de red nuevo e independiente (caso particular) constituye o no un ataque de exfiltración.

1.8.3 TIPO DE INVESTIGACIÓN

De acuerdo con el propósito del estudio y la naturaleza del problema en la infraestructura de Tigo Bolivia, la investigación se clasifica en dos tipologías complementarias:

1.8.3.1 Investigación Aplicada:

El proyecto es fundamentalmente de carácter aplicativo, ya que no busca únicamente generar nuevo conocimiento teórico sobre ciberseguridad, sino que toma fundamentos técnicos ya establecidos (aprendizaje automático, análisis de gradientes, arquitecturas de alto rendimiento) para resolver un problema práctico, específico y urgente, pues, como nos dice Rodríguez-Toro, (2024) "Se conoce como el nivel de la investigación aplicada, y su propósito es mejorar. Es el uso de la estadística para el control de la calidad industrial" (p. 63).

1.8.3.2 Investigación Predictiva:

El estudio también adopta un nivel predictivo debido a la integración central del modelo matemático LightGBM y como explica Rodríguez-Toro, (2024) “En este nivel se predice probabilísticamente la ocurrencia de eventos, utilizando los datos obtenidos en el pasado. Se construyen modelos predictivos” (p. 62). A diferencia de los métodos descriptivos que solo analizan incidentes pasados, el proyecto aplica un enfoque de clasificación supervisada. El sistema aprenderá de los patrones de red y de las características de un conjunto de datos etiquetado, con el objetivo de clasificar y el tráfico continuo y calcular probabilísticamente su pertenencia a la clase anómala (exfiltración) antes de que el ataque se complete.

1.8.4 OPERACIONALIZACIÓN DE VARIABLES

En el proyecto se busca optimizar el tiempo y la precisión en la detección de exfiltración de datos mediante el uso de un algoritmo de Gradient Boosting, lo cual metodológicamente se traduce en reducir el tiempo de alerta y mejorar la precisión de clasificación. Las variables se extraen del título oficial “Sistema web aplicando el algoritmo Light Gradient Boosting Machine para la optimización del tiempo y precisión en la detección de exfiltración de datos”, de donde se establecen formalmente la Variable Dependiente (Variable 1: Optimización del tiempo y la precisión en la detección) y la Variable Independiente (Variable 2: Sistema web basado en el algoritmo LightGBM como solución interventora).

Cuadro 1.1 Operacionalización de Variables

Variable	Dimensión	Indicadores	Escala	Técnicas	Instrumentos
V1: Optimización del tiempo y precisión en detección	**Velocidad de Respuesta**	Tiempo Medio de Detección (MTTD) de vectores de exfiltración de datos.	Milisegundos (ms)	Experimentación Controlada mediante Simulación de Tráfico y Vectores de Ataque.	Tablero de control interactivo (*dashboard*) en tiempo real.
					Logs de auditoría con marcas de tiempo (*timestamps* con resolución de microsegundos)
	Precisión Predictiva	Tasa de Falsos Positivos (FPR).	Porcentaje	Evaluación Estadística de Modelos de	Matriz de confusión generada por el motor del algoritmo LightGBM.

Variable	Dimensión	Indicadores	Escala	Técnicas	Instrumentos
		Puntaje F1 (*F1-Score*).	Escala de 0 a 1	Clasificación Binaria	Reportes estructurados de métricas de evaluación de IA generados durante la fase de pruebas expresados en una proporción de 0.0 a 1.0.
V2 Sistema web basado en el algoritmo LightGBM	**Despliegue y Arquitectura**	Latencia de respuesta de la API	Milisegundos (ms)	Medición Técnica Automatizada e Instrumentación de Código (*Profiling* de Software).	Módulo de telemetría asíncrona integrado en el backend de Axum
		Volumen de memoria RAM consumida en el análisis	Megabytes (MB)		Logs de diagnóstico de rendimiento del servidor e instrumentación de hilos con Tokio-console.
	Procesamiento de Datos	Tiempo de extracción de características por millón de registros.	Segundos (s)	Pruebas de Carga Estadísticas e Ingesta de Datos.	Scripts de automatización y funciones de medición temporal nativas en Rust
					Registros de rendimiento y métricas de procesamiento interno del motor analítico.

Fuente. Elaboración Propia, 2026.

1.8.4.1 Técnicas

Para la presente investigación se emplearán técnicas de recolección y medición de datos que permitan obtener información pertinente, objetiva y cuantificable respecto a las variables definidas. En ese sentido, debido a la naturaleza técnica, arquitectónica y computacional del estudio, se utilizarán cuatro técnicas principales: la Medición Técnica Automatizada e

Instrumentación de Código (Profiling de Software), las Pruebas de Carga Estadísticas e Ingesta de Datos, la Experimentación Controlada mediante Simulación de Tráfico y Vectores de Ataque, y la Evaluación Estadística de Modelos de Clasificación Binaria. Estas técnicas se justifican por su adecuación para analizar tanto el rendimiento del sistema web propuesto como su eficacia predictiva frente a vectores de exfiltración en un entorno de telecomunicaciones.

La técnica de Medición Técnica Automatizada e Instrumentación de Código (Profiling de Software) se empleará con el propósito de analizar el comportamiento del backend y la arquitectura de despliegue en un entorno real. Esta técnica se justifica debido a que posibilita identificar aspectos relacionados con la eficiencia del sistema, tales como la latencia de respuesta de la API y el volumen de memoria RAM consumida. Se aplicará mediante la instrumentación directa del código fuente, considerando las dimensiones de Despliegue y Arquitectura establecidas en la operacionalización de la Variable 1.

También, se utilizará la técnica de Pruebas de Carga Estadísticas e Ingesta de Datos, la cual permitirá recolectar información cuantitativa sobre el rendimiento del motor de procesamiento. Esta técnica se considera adecuada debido a que facilita la medición del tiempo de extracción de características por millón de registros bajo estrés computacional. Se aplicará tomando en cuenta los indicadores de la dimensión de Procesamiento de Datos de la Variable 1.

Se aplicará la técnica de Experimentación Controlada mediante Simulación de Tráfico y Vectores de Ataque, con el propósito de medir la Velocidad de Respuesta del sistema. Esta técnica se justifica al permitir la inyección controlada de anomalías para calcular el Tiempo Medio de Detección (MTTD) en un entorno seguro y aislado.

De igual manera, se empleará la técnica de Evaluación Estadística de Modelos de Clasificación Binaria, la cual permitirá recolectar datos cuantitativos sobre la Precisión Predictiva del algoritmo. Esta técnica es fundamental para calcular métricas como la Tasa de Falsos Positivos (FPR) y el Puntaje F1 (F1-Score), garantizando la fiabilidad matemática del modelo de inteligencia artificial implementado.

1.8.4.2 Instrumentos

De acuerdo con las técnicas seleccionadas, se diseñarán, configurarán y usarán los instrumentos para recolectar datos de manera sistemática, automatizada y ordenada. Estas

herramientas son el software específico, la telemetría y los reportes analíticos que permiten la aplicación de cada técnica.

Para la técnica de Medición Técnica Automatizada e Instrumentación de Código, se usarán el módulo de telemetría asíncrona del backend de Axum (para captar la latencia) y los logs de diagnóstico del rendimiento del servidor e instrumentación de hilos con Tokio-console (para medir el uso de memoria RAM). Estos instrumentos registrarán de forma objetiva cómo se comporta el sistema a nivel de sistema operativo y framework.

Respecto a la técnica de Pruebas de Carga Estadísticas e Ingesta de Datos, se emplearán los scripts de automatización y funciones de medición temporal que vienen con Rust, así como los registros de rendimiento y métricas del motor analítico columnar Polars. Así, se capturarán los tiempos exactos de extracción de características y el rendimiento del procesamiento de grandes volúmenes de datos.

Para la técnica de Experimentación Controlada mediante Simulación de Tráfico, se usarán el tablero de control interactivo (dashboard) en tiempo real (para visualizar alertas) y los logs de auditoría con marcas de tiempo (timestamps de microsegundos). Estos instrumentos serán clave para calcular con precisión el Tiempo Medio de Detección (MTTD) de los vectores de exfiltración simulados.

En la técnica de Evaluación Estadística de Modelos de Clasificación Binaria, se utilizarán la matriz de confusión generada por el motor del algoritmo LightGBM y los reportes estructurados de métricas de evaluación de IA generados durante la fase de pruebas (15% del dataset). Así, se podrá cuantificar el rendimiento predictivo calculando las métricas mediante las siguientes fórmulas matemáticas:

- Tasa de Falsos Positivos (FPR): $FPR = \frac{FP}{FP+VN}$ (donde FP representa los Falsos Positivos y VN los Verdaderos Negativos clasificados por el modelo).
- Puntaje F1 (F1-Score): $F1 = 2 \times \frac{Precision \times Sensibilidad}{Precision + Sensibilidad}$ (calculado como la media armónica entre la precisión y la sensibilidad del algoritmo).
- Tiempo Medio de Detección (MTTD): $MTTD = \frac{\sum(T_{deteccion} - T_{inicio})}{Total\ de\ Incidentes}$

La aplicación sistemática de estas fórmulas sobre los datos de los instrumentos asegurará la validez, objetividad y confiabilidad de la precisión predictiva del modelo, garantizando la coherencia metodológica de la investigación.

Los instrumentos elegidos y configurados se diseñaron pensando en su relevancia para medir los indicadores técnicos definidos en la matriz de operacionalización, garantizando de este modo la coherencia metodológica de la investigación.

1.8.5 DISEÑO DE INVESTIGACIÓN

Considerando que se utiliza un método analítico-deductivo en un escenario aplicativo y cuantitativo, el diseño de la investigación es Cuasi-experimental.

> La investigación cuasi experimental guarda similitudes con los trabajos experimentales; sin embargo, su principal particularidad es que, en esta, los sujetos de investigación no se asignan de manera aleatoria a los grupos que conforman el experimento; en cambio, se asignan por criterios definidos por el investigador o determinados por el contexto. (Reyez y Reyez, 2024, p. 146)

Para el presente estudio, no se utilizarán dos grupos físicos independientes, sino que se evaluará la misma infraestructura bajo un esquema de pre-prueba (operación con los sistemas tradicionales actuales de IDS y DLP) y post-prueba (tras la intervención del nuevo sistema web propuesto). Las métricas comparadas para medir la mejora serán el Tiempo Medio de Detección (MTTD) y la tasa de falsos positivos.

1.8.5.1 Fase de Pre-prueba (Línea Base del Grupo de Control):

Se establecerá una línea base evaluando la eficacia de los sistemas tradicionales actuales (IDS y DLP basados en firmas) dentro de la infraestructura de Tigo Bolivia. Para esto, se recolectarán métricas sobre el MTTD actual y el porcentaje de falsos positivos que saturan el análisis manual, midiendo el comportamiento operativo de dichos sistemas tradicionales ante los escenarios de prueba o simulaciones iniciales de tráfico corporativo.

1.8.5.2 Fase de Post-prueba (Medición de Resultados):

Se recolectarán las nuevas métricas generadas por el sistema web ante los mismos flujos de datos o escenarios de prueba controlados. Para realizar la evaluación comparativa, los registros del conjunto de prueba también serán procesados a través de la emulación de las reglas de los sistemas tradicionales (IDS/DLP), permitiendo extraer sus reportes de alertas bajo las mismas condiciones de ejecución.

Se contrastarán los resultados cuantitativos de la Pre-prueba frente a la Post-prueba. Esto permitirá documentar de manera objetiva y empírica la optimización de los tiempos de respuesta y la mejora en la precisión predictiva, validando así la viabilidad de la arquitectura propuesta.

1.8.6 POBLACIÓN

La población de la presente investigación no abarca la totalidad de la infraestructura física del proveedor, sino que está conformada estrictamente por los registros históricos de auditoría y tráfico de red (logs) capturados, almacenados y disponibles para análisis en el entorno del Centro de Operaciones de Seguridad (SOC) de Tigo Business. Esta población incluye exclusivamente los eventos generados por los dispositivos críticos de seguridad (firewalls, sistemas IDS/IPS y servidores DNS) que son exportados al gestor central.

Debido a la magnitud de la operadora, este volumen posee una naturaleza de Big Data, caracterizada por su alta velocidad, flujo constante y un marcado desbalance de clases, donde el tráfico legítimo predomina abrumadoramente sobre los intentos de exfiltración. Para efectos de procesamiento práctico y viabilidad investigativa, se delimita la población temporalmente al histórico de tráfico generado durante un periodo de observación de 30 días continuos.

Esto establece un universo cuantificable de 1.500.000.000 (mil quinientos millones) de eventos digitales y registros de red mensuales. El tamaño de esta población no se estima sobre usuarios finales externos, sino que se justifica documentalmente a partir de la volumetría operativa real reportada por la ingeniería del SOC de la organización, la cual procesa un promedio de 50 millones de eventos de seguridad diarios Véase Apéndice 3.

1.8.7 MUESTRA

Para el desarrollo y entrenamiento del modelo predictivo, se extraerá una muestra representativa equivalente al 2% de la población mensual calculada, lo que corresponde a treinta millones, que incluyen flujos IP y eventos transaccionales sometidos a procesos de ingeniería de características. La selección de este volumen responde a la naturaleza altamente desbalanceada de los eventos de ciberseguridad, donde los intentos de exfiltración representan una fracción extremadamente minoritaria respecto al tráfico legítimo total. Esta proporción permite mantener un volumen de datos manejable computacionalmente mientras se garantiza la representatividad de los eventos de red.

Considerando una incidencia estimada inferior al 0.01% para eventos potencialmente asociados a exfiltración de datos en redes de telecomunicaciones (Nokia, 2024), una muestra de menor tamaño podría generar una representación insuficiente de la clase minoritaria, limitando la capacidad de aprendizaje del modelo.

Debido a que las fórmulas estadísticas probabilísticas clásicas para poblaciones finitas no son aplicables para el entrenamiento de modelos de Machine Learning en entornos de Big Data donde una muestra estándar de n=384 omitiría los eventos anómalos, el tamaño de la muestra se determinó mediante un muestreo intencional orientado a la retención de la clase minoritaria. Para garantizar que el modelo LightGBM disponga de suficientes datos positivos para aprender patrones válidos, se extrajo una muestra del 2% del tráfico mensual poblacional, equivalente a 30,000,000 de registros, lo cual asegura estadísticamente la captura de al menos 3,000 eventos reales de exfiltración.

En consecuencia, se aplicará un muestreo estratificado, dividiendo la población total estimada ($N = 1{,}500{,}000{,}000$ de eventos) según el tipo de protocolo de red. A partir de una muestra de $n = 30{,}000{,}000$, se determinó la cantidad de registros por estrato de manera proporcional mediante la fórmula:

$$n_h = \frac{N_h}{N} \cdot n$$

Tráfico TCP (70% de la población):

$$n_h = \frac{10{,}500{,}000{,}000}{15{,}000{,}000{,}000} \times 30{,}000{,}000$$

$$n_h = 0.70 \times 30{,}000{,}000 = 21{,}000{,}000$$

Tráfico UDP (20% de la población):

$$n_h = \frac{3{,}000{,}000{,}000}{15{,}000{,}000{,}000} \times 30{,}000{,}000$$

$$n_h = 0.20 \times 30{,}000{,}000 = 6{,}000{,}000$$

Tráfico ICMP (10% de la población):

$$n_h = \frac{1{,}500{,}000{,}000}{15{,}000{,}000{,}000} \times 30{,}000{,}000$$

$$n_h = 0.10 \times 30{,}000{,}000 = 3{,}000{,}000$$

Como resultado, se seleccionarán 21,000,000 de registros TCP, 6,000,000 de UDP y 3,000,000 de ICMP, garantizando la representatividad de cada grupo dentro de la muestra total.

Para evitar el sesgo de selección dentro de cada estrato, los registros de red específicos serán extraídos utilizando un generador automatizado de números aleatorios sobre los logs

históricos. Este procedimiento garantiza que todo el tráfico capturado en la ventana temporal tenga la misma probabilidad de ser evaluado y seleccionado para la muestra.

Este procedimiento permitirá preservar proporcionalmente eventos críticos asociados a la exfiltración de datos garantizando representatividad analítica y capacidad de generalización del modelo predictivo.

La muestra total se dividirá operativamente en tres subconjuntos cronológicos: 70% para entrenamiento, 15% para validación y 15% para pruebas (conjunto ciego). Para evitar el sobreajuste y la fuga de información (data leakage) propia del análisis de tráfico de red, no se aplicará una validación cruzada aleatoria (K-Fold tradicional) de manera indiscriminada sobre todo el dataset. En su lugar, la evaluación interna y ajuste de hiperparámetros se realizará exclusivamente sobre el conjunto de entrenamiento utilizando una validación cruzada para series temporales (Time Series Split), respetando la dependencia secuencial de los eventos.

Para resolver el desbalance de clases sin perder la integridad de los datos legítimos, se configurará en el algoritmo LightGBM el parámetro hiper-optimizado de pesos de clase, permitiendo penalizar severamente al modelo durante el entrenamiento cuando no detecte correctamente la clase minoritaria

CAPITULO II

MARCO TEÓRICO

CAPITULO II
MARCO TEÓRICO

2.1 MARCO TEÓRICO

2.1.1 INGENIERIA DE SOFTWARE

La ingenieria de software es una disciplina encargada de gestionar el software desde su producción hasta su mantenimiento, como nos dicen Celi, et al., (2023) “La ingeniería de software es una disciplina de ingeniería que se interesa por todos los aspectos de la producción de software, desde las primeras etapas de la especificación del sistema hasta el mantenimiento del sistema después de que se pone en operación” (p. 14)

2.1.1.1 Fundamentos y Principios de Ingeniería de Software

2.1.1.1.1 Don’t Repeat Yourself (Dry)

Este principio se enfoca principalmente en evitar repetir y ser redundante con el código y distintas funcionalidades, otros autores afirman que:

> Este es un principio que se infringe con regularidad por los principiantes, el cual se traduce a “No te repitas” y lo que nos dice es que debemos evitar duplicar código o funcionalidad.
>
> No repetir código o funcionalidad puede resultar lógico, sin embargo, es muy común ver programadores que copian y pegan fragmentos de código, o arquitectos que diseñan componentes que repiten funcionalidad en más de un módulo, lo que puede complicar mucho la administración, el mantenimiento y la corrección de bugs. (Blancarte, 2020, p.49)

2.1.1.1.2 Separation Of Concerns (Soc)

Se define como la separación de preocupaciones donde cada parte del programa se encargue de una sola cosa en distintas secciones, Blancarte (2020) detalla a “SoC o Separación de preocupaciones o separación de conceptos o separación de intereses en español, propone la separación de un programa en secciones distintas, de tal forma que cada sección se enfoque en resolver una parte delimitada del programa” (p. 50).

2.1.1.1.3 Keep It Simple, Stupid! (Kiss)

Concepto cuya traduccion directa significa ¡Mantenlo simple, estúpido!, hace referencia a que no es necesario volver el código más complejo si no es necesario pues como dice Blancarte (2020) “La mejor solución no es la más elaborada o compleja, sino la más simple” (p. 54).

2.1.1.1.4 Inversión Of Control (Ioc)

Esta es una forma de trabajo en la que el control que suele ser de la aplicación al framework sea invertida donde el framework se ejecuta sobre la ap, otros autores describen:

> Pues bien, IoC se basa en la introspección (en Java llamado Reflection) el cual es un procedimiento por el cual leemos metadatos de la Ap que nos permita entender cómo funciona. Los metadatos pueden estar expresados principalmente de dos formas, la primera es mediante archivos de configuración como XML o con metadados directamente definidos sobre las clases de nuestro programa, en Java estos metadatos son las @Annotations o anotaciones y es por medio de estos metadatos y con técnicas de introspección que es posible entender el funcionamiento de la Ap. (Blancarte, 2020, p. 56)

2.1.1.2 Principios SOLID

Estos son los principios más importantes para el desarrollo de una aplicación, así lo destaca Blancarte (2020) que define a solid “el cual es en realidad de unión de 5 principios que para muchos son los más importantes de todos, este acrónimo fue introducido por primera vez a principios de la década del 2000 por Robert C. Martin (mejor conocido por muchos como el tío Bob)” (p. 57).

2.1.1.2.1 Single Responsibility Principle (SRP)

Este principio nos dice que cada parte del programa debe tener una única responsabilidad, Blancarte (2020) nos detalla lo siguiente:

> Este principio establece que cada función, clase o módulo debe de tener una única responsabilidad dentro del software al que pertenece, al mismo tiempo que toda su funcionalidad debe de estar encapsulada.
>
> Este principio previene que desvirtuemos el propósito para el cual hemos creado una función, clase o módulo, agregando elementos que no están relacionados a resolver el problema para el cual existe. (p. 57)

2.1.1.2.2 Open/Closed Principle (OCP)

El cual expresa que toda función está abierta a ser extendida y escalada pero no está sujeta a recibir modificaciones

Otros autores dirán:

> Básicamente lo que dice este principio es que cualquier unidad de software que creemos deberá poder extenderse para ampliar su funcionalidad, es decir, mejorar con ciertas restricciones el software, pero debemos evitar (cerrar) que lo modifiquen, es decir, debemos evitar que el programador altere el propósito para el cual esta echo o modifique el funcionamiento core del componente. (Blancarte, 2020, p. 58)

2.1.1.2.3 Liskov Substitution Principle (LSP)

Este quiere decir de acuerdo con Blancarte (2020) que se refiere a todo objeto de tipo T se puede sustituir por un objeto de subtipo S es decir un subtipo S que extiende a la clase base T.

2.1.1.2.4 Interface Segregation Principle (ISP)

Este indica que el cliente solo debe conocer los métodos que va a utilizar separando los métodos de una interfaz grande en interfaces pequeñas, Blancarte (2020) nos lo detalla:

> La idea que propone es separar los métodos de una interfaz con una gran cantidad de métodos, en varias interfaces más pequeñas y cohesivas, de tal forma que cada interface tenga un rol especifico, permitiendo al cliente ignorar al resto de interfaces y centrarse únicamente en la que necesita, reduciendo el número de método y la complejidad de la misma. A este tipo de interface reducidas se les conoce como Interfaces de rol. (p. 61)

2.1.1.2.5 Dependency Inversion Principle (DIP)

Este principio nos habla de que no debe existir dependencia entre módulos sino entre abstracciones, según Blancarte (2021):

> • Los módulos de alto nivel no deben depender de módulos de bajo nivel. Ambos deben depender de las abstracciones.
>
> • Las abstracciones no deben depender de los detalles. Los detalles deben depender de las abstracciones. (p. 83)

2.1.1.3 Ciclo de Vida del Software

Para (Pressman y Maxim, 2021) el ciclo de vida del software se puede definir como:

> El marco de trabajo de un proceso establece la base para un proceso de ingeniería de software completo mediante la identifi cación de un pequeño número de actividades del marco de trabajo que sean aplicables a todos los proyectos de software, sin importar su tamaño o complejidad. Además, el marco de trabajo del

proceso abarca un conjunto de actividades sombrilla que se aplican a lo largo de todo el proceso de software. Un marco de trabajo de proceso genérico para la ingeniería de software cubre cinco actividades: (p. 10)

2.1.1.3.1 Comunicación

Antes de poder comenzar cualquier trabajo técnico, es muy importante comunicarse y colaborar con el cliente (y otros interesados).8 Se pretende entender los objetivos que tienen los interesados para el proyecto y recopilar los requerimientos que ayuden a definir las características y funciones del software. (Pressman y Maxim, 2021. p. 10)

2.1.1.3.2 Planeación

Cualquier viaje complicado puede simplifi carse si existe un mapa. Un pro yecto de software es un viaje complicado; la actividad de planeación crea un “mapa” que ayuda a guiar al equipo durante el trayecto. El mapa (que se conoce como plan de proyecto de software) defi ne el trabajo de ingeniería de software al describir las tareas técnicas que se van a realizar, los probables riesgos, los recursos que se requerirán, los productos de trabajo a generar y un calendario de trabajo. (Pressman y Maxim, 2021. p. 10)

2.1.1.3.3 Modelado

Si usted es paisajista, construye puentes, es ingeniero aeronáutico, carpintero o arquitecto, entonces trabaja con modelos a diario. Crea un “bosquejo” de su objetivo para poder entender el panorama en general: cómo se verá arquitectónicamente, cómo se unen las partes que lo constituyen y muchas otras características. Si se requiere, puede refi nar el bosquejo con mayor detalle para tratar de entender mejor el problema y cómo resolverlo. Un ingeniero de software hace lo mismo al crear modelos para entender mejor los requerimientos de software y el diseño que cumplirá con dichos requerimientos. (Pressman y Maxim, 2021. p. 10)

2.1.1.3.4 Construcción

Pressman y Maxim, (2021) “Lo que diseña debe construirse. Esta actividad combina la generación de código (ya sea manual o automatizada) y las pruebas requeridas para descubrir los errores en el código” (p.10).

2.1.1.3.5 Implementación

“El software (como una entidad completa o como un incremento par cialmente completado) se entrega al cliente, quien a su vez evalúa el producto entregado y provee retroalimentación con base en dicha evaluación” (Pressman y Maxim, 2021. p. 10).

Figura 2.1 Ciclo de Vida del Software



Fuente: Pressman y Maxim (2021)

2.1.2 MODELOS DE DESARROLLO

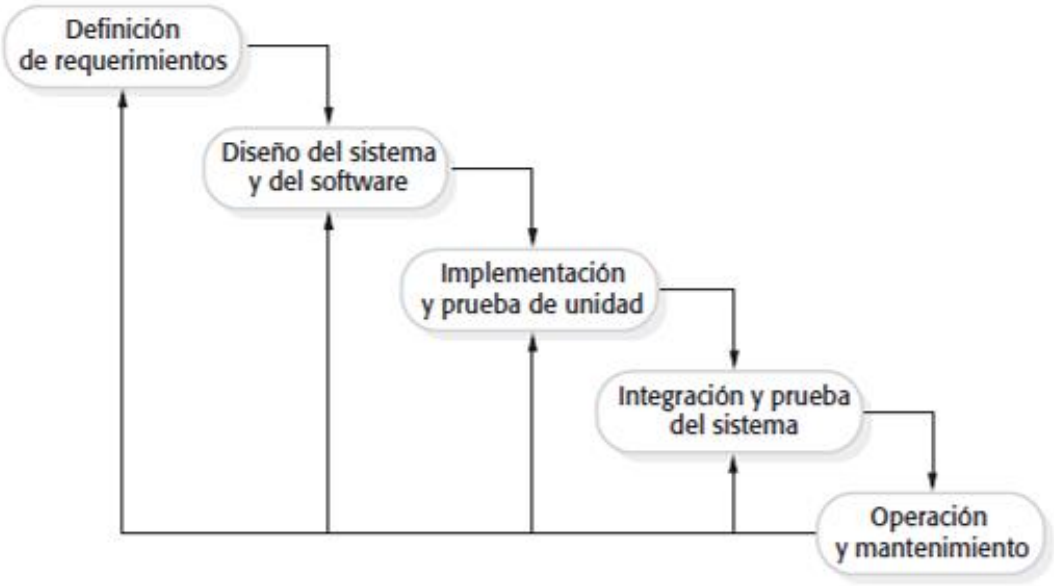
De acuerdo con Celi et al., (2023):

> Un proceso de software es una serie de actividades relacionadas que conduce a la elaboración de un producto de software. Estas actividades pueden incluir el desarrollo de software desde cero en un lenguaje de programación estándar como Java o C. Sin embargo, las aplicaciones de negocios no se desarrollan precisamente de esta forma. El nuevo software empresarial con frecuencia ahora se desarrolla extendiendo y modificando los sistemas existentes, o configurando e integrando el software comercial o componentes del sistema. (p. 21)

2.1.2.1 El Modelo en Cascada

Basado en una cascada donde todas las fases están separadas, Celi et al., (2023) nos especifica: “Éste toma las actividades fundamentales del proceso de especificación, desarrollo, validación y evolución y, luego, los representa como fases separadas del proceso, tal como especificación de requerimientos, diseño de software, implementación, pruebas, etcétera” (p. 22)

Figura 2.2 Esquema del Modelo en Cascada



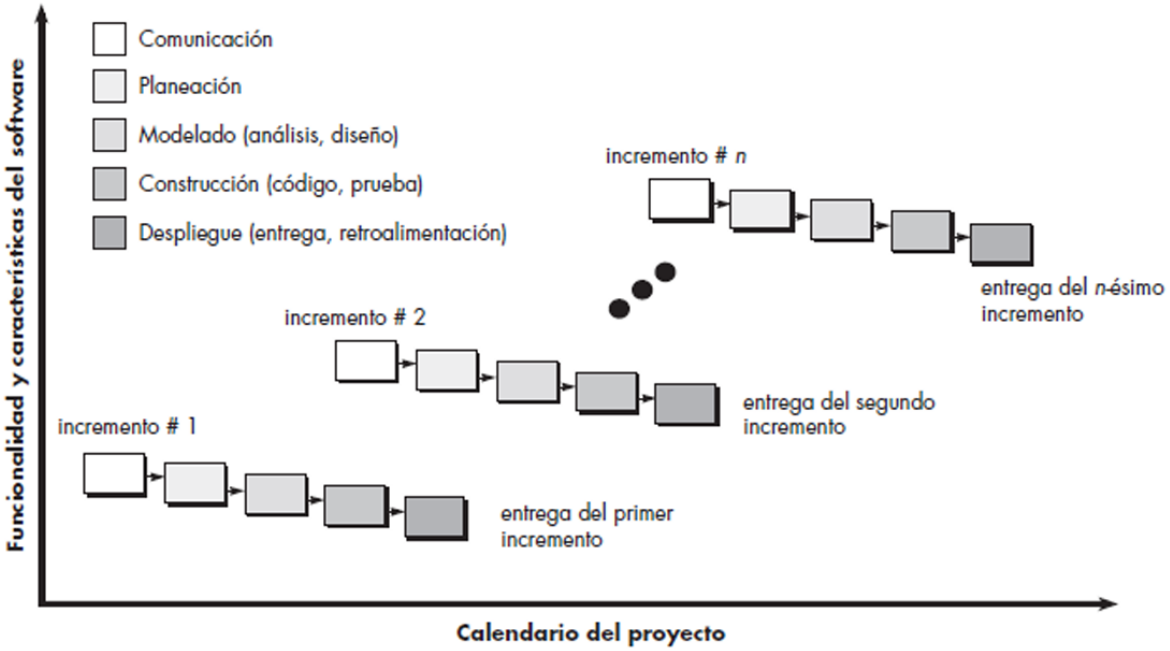
Fuente. Tomado de Celi et al., (2023).

2.1.2.2 Modelo incremental

Está enfocado en decir que cada incremento entrega un producto de valor que ya funciona y cumple una parte del objetivo final. Otros autores dicen:

> El desarrollo incremental es útil en particular cuando no se dispone de personal para la implementación completa del proyecto en el plazo establecido por el negocio. Los primeros incrementos se desarrollan con pocos trabajadores. Si el producto básico es bien recibido, entonces se agrega más personal (si se requiere) para que labore en el siguiente incremento. Además, los incrementos se planean para administrar riesgos técnicos. Por ejemplo, un sistema grande talvez requiera que se disponga de hardware nuevo que se encuentre en desarrollo y cuya fecha de entrega sea incierta. En este caso, tal vez sea posible planear los primeros incrementos de forma que eviten el uso de dicho hardware, y así proporcionar una funcionalidad parcial a los usuarios finales sin un retraso importante. (Celi et al,. 2023, p. 23)

Figura 2.3 Esquema del Modelo Incremental



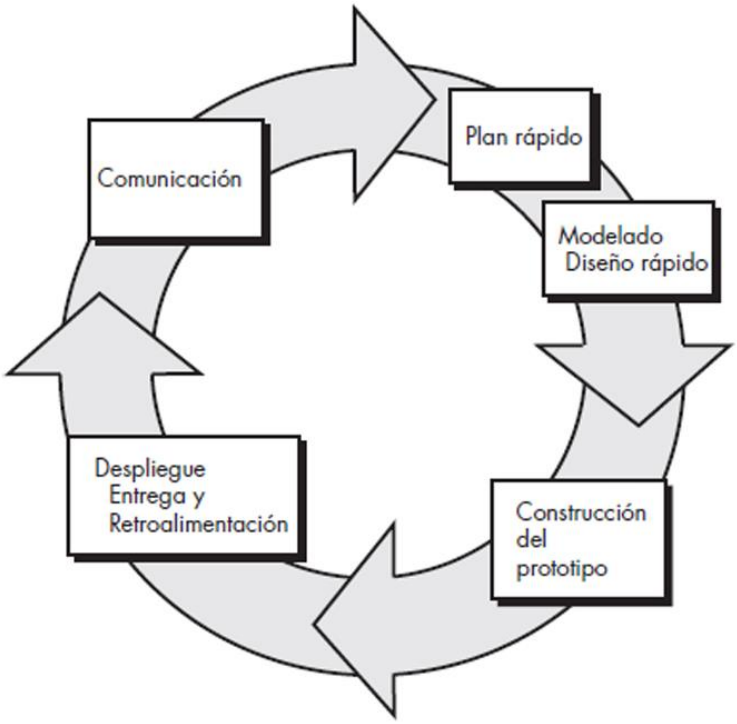
Fuente. Celi et al., (2023).

2.1.2.3 Modelo Evolutivo

Estos son modelos iterativos que se caracterizan por la realización de varios entregables y versiones de un producto. Celi et al., (2023) nos expone:

> El paradigma de hacer prototipos comienza con comunicación. Usted se reúne con otros participantes para definir los objetivos generales del software, identifica cualesquiera requerimientos que conozca y detecta las áreas en las que es imprescindible una mayor definición. Se planea rápidamente una iteración para hacer el prototipo, y se lleva a cabo el modelado (en forma de un “diseño rápido”). Éste se centra en la representación de aquellos aspectos del software que serán visibles para los usuarios finales (por ejemplo, disposición de la interfaz humana o formatos de la pantalla de salida). (p. 24-25)

Figura 2.4 Esquema de Modelo Evolutivo



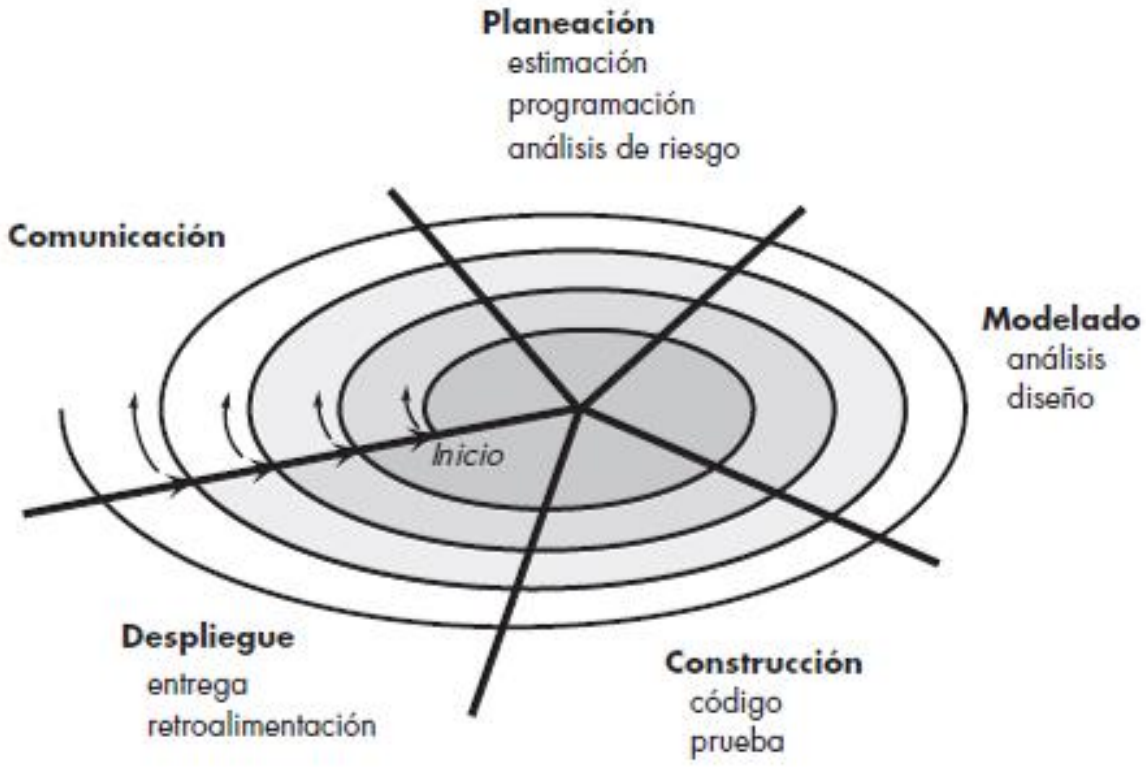
Fuente. Celi et al., (2023).

2.1.2.4 Modelo Espiral

Es un modelo evolutivo acoplado con los prototipados, otros autores nos afirman:

> El modelo espiral. Propuesto en primer lugar por Barry Boehm, el modelo espiral es un modelo evolutivo del proceso del software y se acopla con la naturaleza iterativa de hacer prototipos con los aspectos controlados y sistémicos del modelo de cascada. (Celi et al,. 2023, p. 25)

Figura 2.5 Esquema del Modelo Espiral



Fuente. Celi et al., (2023).

2.1.2.5 Modelo Seleccionado

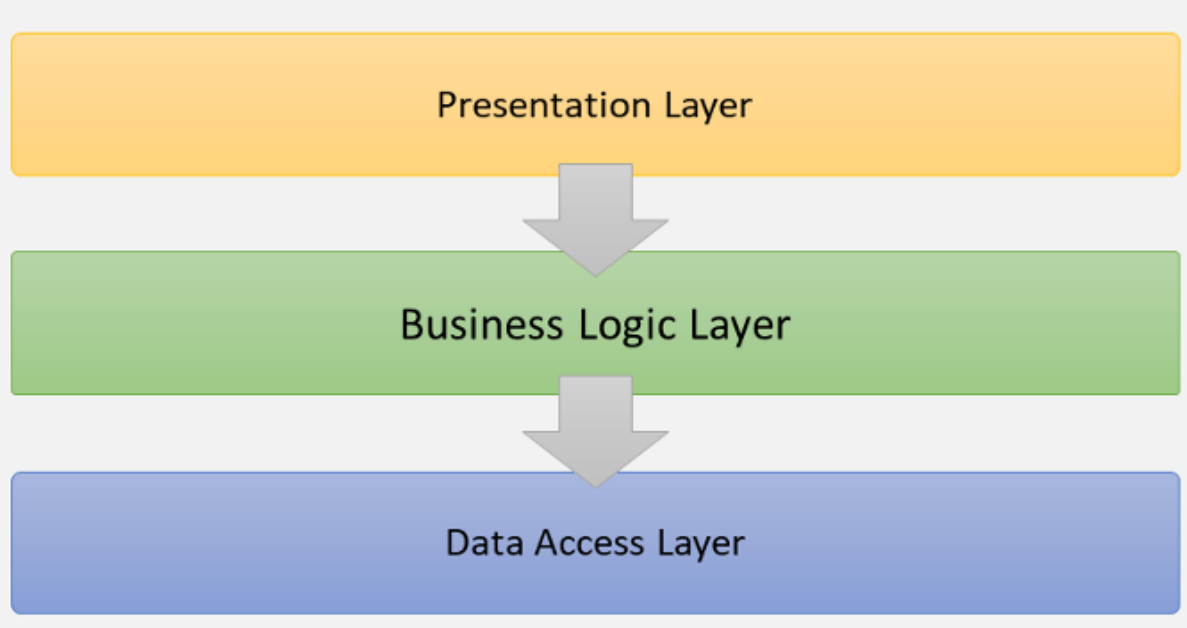
El modelo de proceso de software seleccionado es el modelo incremental con un enfoque iterativo. Este modelo se ajusta al proyecto, ya que no exige contar con requisitos estáticos desde el inicio, sino que permite la entrega de software funcional en partes más pequeñas y manejables denominadas incrementos. La implementación de este modelo conceptual se llevará a cabo a través del marco de trabajo ágil.

2.1.3 ARQUITECTURA DE SISTEMA

2.1.3.1 Arquitectura en 3 Capas

Esta arquitectura nos ayuda a definir las capas de la construcción de la arquitectura para la aplicación y nos dice que debe hacer cada una de ellas, con esta arquitectura también podemos combatir uno de los problemas más comunes pues como expone Blancarte (2020) es común construir una aplicación como una masa sin forma donde un solo componente se encarga de la lógica de negocio, acceso y presentación, esto causaba infracciones del principio DRY, es así que esta arquitectura propone las siguientes capas.

Figura 2.6 Esquema Arquitectura 3 Capas



Fuente: Blancarte, (2020).

2.1.3.1.1 Capa De Presentación

Esta capa se encarga de crear la vista y la interfaz gráfica, esta capa "es la encargada de crear la vista o interfaz gráfica de usuario, puede ser una aplicación web, una ap de escritorio o una ap móvil. Generalmente escrito en HTML, Javascript, CSS, Android/Swift, etc" (Blancarte, 2020, p. 153).

2.1.3.1.2 Capa De Lógica De Negocio

La capa encargada de las operaciones, de acuerdo con Blancarte (2020) "esta capa contiene la lógica de negocio y las operaciones de alto nivel que la capa de presentación puede utilizar" (p. 153).

2.1.3.1.3 Capa De Acceso De Datos

Esta capa es aquella encargada de los datos y su acceso por ejemplo MySQL, Oracle, PostgreSQL, MongoDB entre otros, mediante por ejemplo la cadena de conexión u otros elementos similares Blancarte (2020).

2.1.3.2 Características de una arquitectura en capas

Las características que distinguen a la arquitectura en capas de las demás para Blancarte (2020) son las siguientes:

- Las capas tienen responsabilidad única.

- Las capas son independientes.
- Al menos tres capas.
- Comunicación descendente.

2.1.3.3 Ventajas de Utilizar una Arquitectura en Capas

Si se seleccionó esta arquitectura es porque tiene sus ventajas y Blancarte (2020) nos expone las siguientes:

- Separación de responsabilidades.
- Fácil de desarrollar.
- Fácil de probar.
- Fácil de mantener.
- Seguridad.

2.1.3.4 Arquitectura en Capas en Aplicaciones Web

Dado la naturaleza de una aplicación web es común ver la estructura en capas pues como detalla Blancarte (2020):

> Las aplicaciones por lo general siguen el patrón arquitectónico conocido como MVC (Modelo-Vista-Controlador), el cual consiste en separar la aplicación en tres partes, la vista (páginas web), los datos (Modelo) y el controlador (lógica de negocio) en partes separadas, lo cual se adapta muy bien con la arquitectura en capas.
>
> En común ver que las aplicaciones de hoy en día se desarrollan en capas, donde por una parte se construye la interface gráfica con tecnologías 100% del FrontEnd como Angular, React o Vue, la cual corresponde a la capa de la vista, luego, llaman a un API REST el cual contiene la capa de negocio y persistencia y finalmente tenemos la base de datos, haciendo que nuestra aplicación tenga 3 o 4 capas, según como se construya la aplicación. (p. 157)

2.1.4 LENGUAJE UNIFICADO DE MODELADO UML

UML (Unified Modeling Language) es un lenguaje que se encarga de modelar los sistemas y los procesos, de acuerdo con Debrauwer y Van Der Heyde (2020):

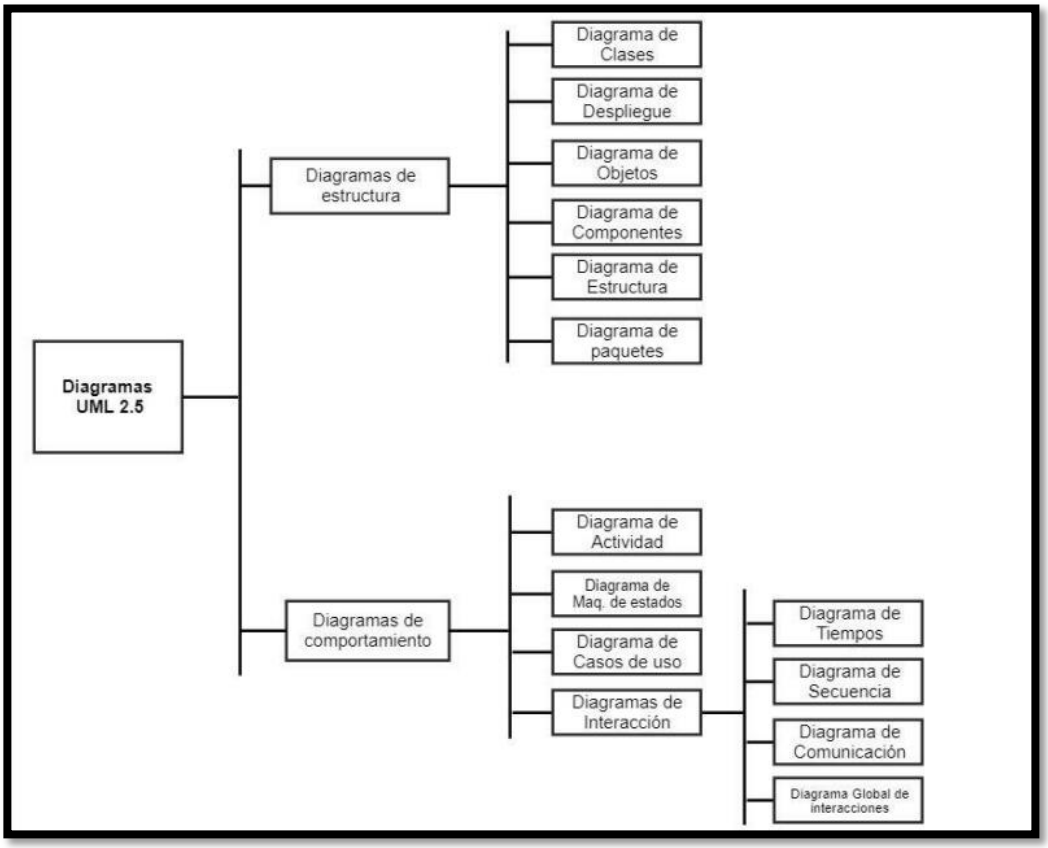
> En un lenguaje de programación la descripción de los objetos se realiza de manera formal utilizando una sintaxis rigurosa. Dicha sintaxis resulta ilegible para los no programadores y difícil de descifrar para los programadores. A diferencia de las máquinas, los humanos prefieren utilizar lenguajes gráficos para representar

> abstracciones, ya que dominan este tipo de lenguaje con mayor facilidad y obtienen una visión de conjunto de los sistemas en mucho menos tiempo. (pp. 17-18)

La finalidad de UML según el Object Management Group (OMG), como se citó en Cubero (2020) es:

> Brindar a los arquitectos de sistemas, ingenieros y desarrolladores de software las herramientas para el análisis, el diseño y la implementación de sistemas basados en software, así como el modelado de procesos de negocios y, además, hacer progresar el estado de la industria permitiendo la interoperabilidad de herramientas de modelado visual de objetos. (p. 3)

Figura 2.7 Tipos de Diagramas UML



Fuente. Tomado de. (Cubero 2020, p. 5).

2.1.4.1 Diagramas de Casos de Uso

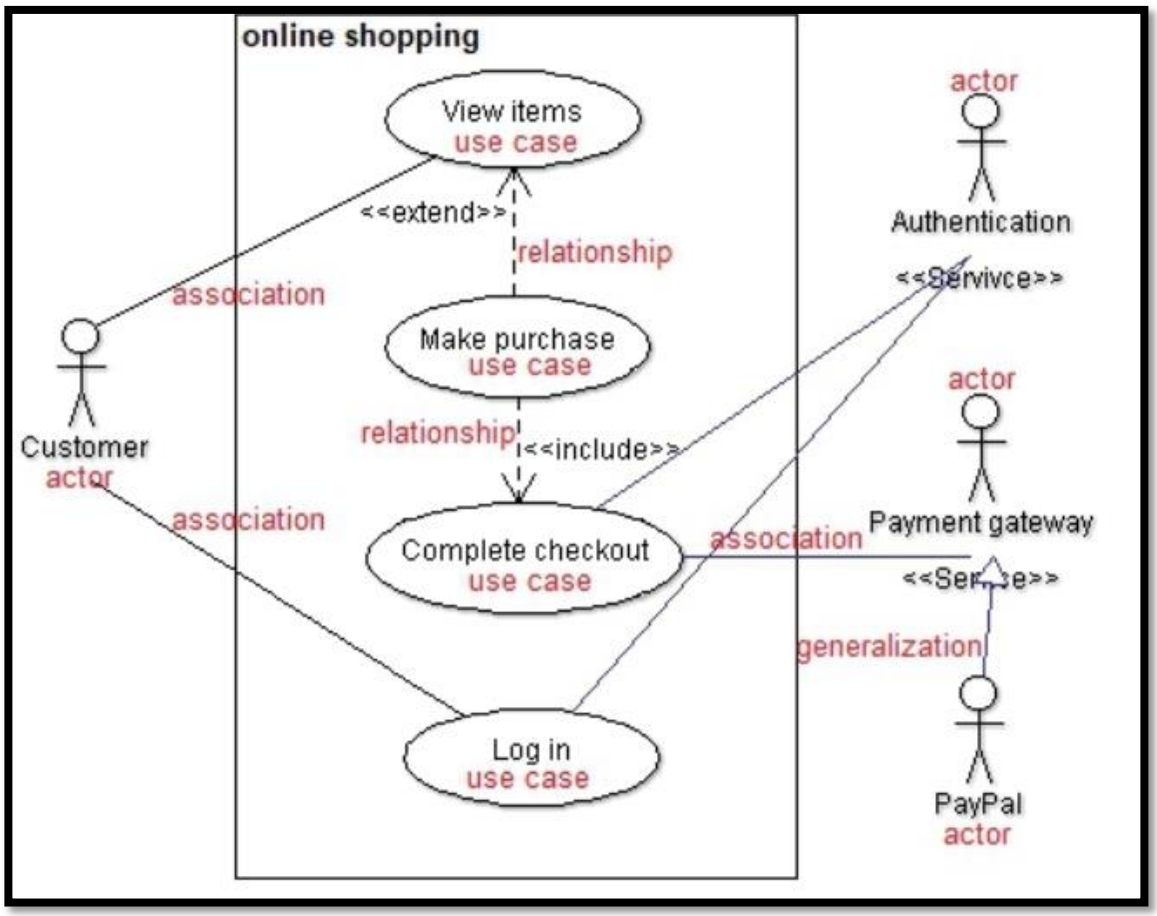
Un caso de uso es un diagrama que describe las acciones e interacciones del sistema con los actores, para Debrauwer y Van Der Heyde (2020):

Los casos de uso describen en forma de lista de acciones y de interacciones el comportamiento del sistema, estudiado desde el punto de vista de los actores. Definen los límites del sistema y sus relaciones con el entorno.

Ahora bien, esta definición debe completarse, ya que no especifica si un caso de uso debe describir la totalidad o sólo una parte del diálogo entre el actor y el sistema. Podría formularse así:

Entre un actor y el sistema, los casos de uso describen las acciones e interacciones vinculadas con un objetivo funcional del actor. (p. 30)

Figura 2.8 Diagrama de Casos de Uso



Fuente. Tomado de. (Aurelio 2024, p. 15).

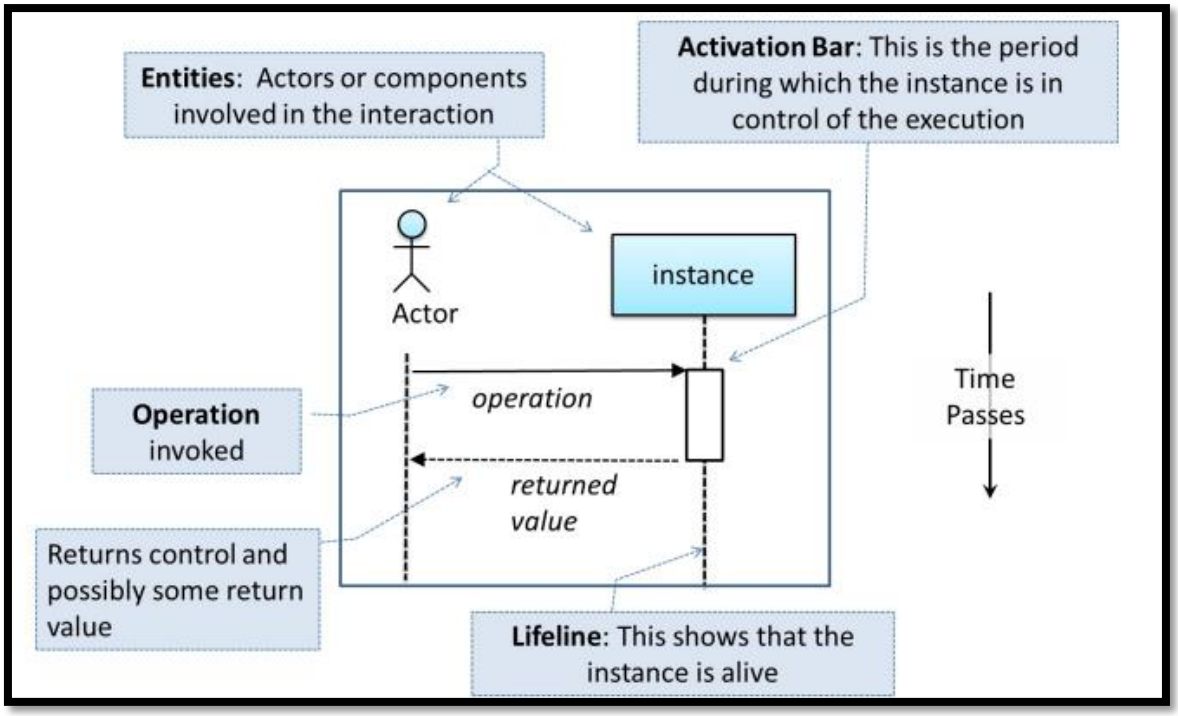
2.1.4.2 Diagrama de Secuencias

Este diagrama es realizado para describir la dinámica del sistema, como detallan Debrauwer y Van Der Heyde (2020):

El diagrama de secuencia describe la dinámica del sistema. A menos que se modele un sistema muy pequeño, resulta difícil representar toda la dinámica de un sistema en un único diagrama. Por tanto, la dinámica completa se representará mediante un conjunto de diagramas de secuencia, cada uno de ellos vinculado generalmente a una subfunción del sistema. Estudiaremos los trucos de interacción que facilitan esta posibilidad de representación.

El diagrama de secuencia describe las interacciones entre un grupo de objetos mostrando de forma secuencial los envíos de mensajes entre objetos. El diagrama puede asimismo mostrar las transmisiones de datos intercambiados durante el envío de mensajes. (p. 50)

Figura 2.9 Diagrama de Secuencias



Fuente. Tomado de. (Aurelio 2024, p. 37).

2.1.4.2.1 Línea De Vida

Este diagrama al representar dinámicas hace interactuar distintas instancias de las clases con las subfunciones vinculadas, esta muestra las acciones y reacciones que tiene cada una de estas instancias, también describe sus periodos de actividad y ejecución (Debrauwer y Van Der Heyde, 2020).

2.1.4.2.2 Mensajes

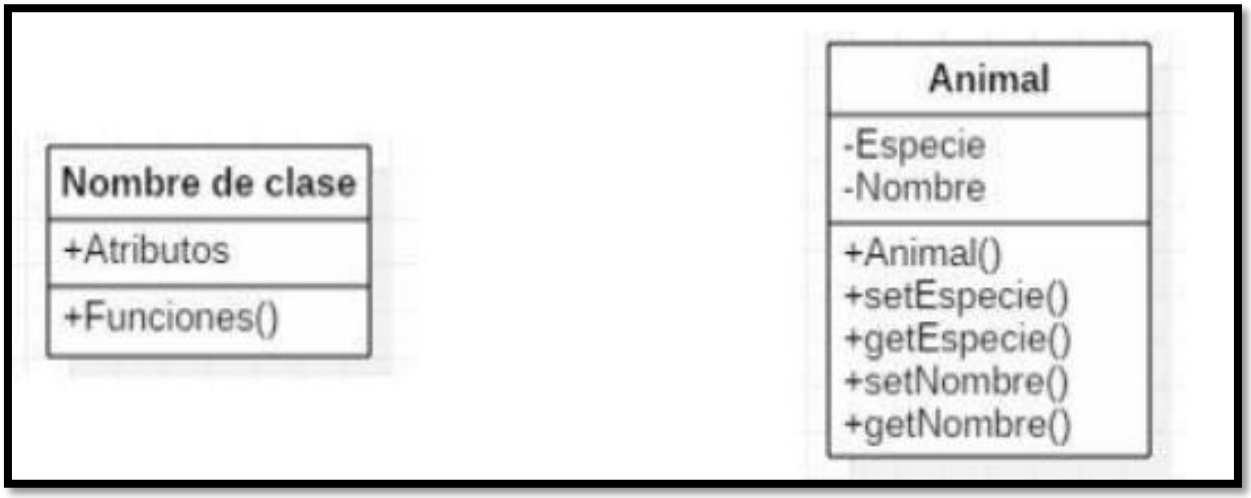
Los mensajes como afirman Debrauwer y Van Der Heyde (2016) son representadas for flechas horizontales y unen a dos lineas de vida representando el envio de mensajes de una instancia a otra instancia.

2.1.4.3 Diagrama de Clases

Los diagramas de clases se hacen para representar a los objetos y las relaciones entre los mismos dentro del sistemas, Debrauwer y Van Der Heyde (2020) afirman lo siguiente:

> El diagrama de clases es una representación estática del sistema. También puede mostrar los objetos, es decir, en un momento determinado, las instancias creadas y sus vínculos cuando el sistema está activo. Las instancias se representan dentro de un rectángulo con su nombre subrayado y, eventualmente, el valor de uno o varios atributos. (p. 115)

Figura 2.10 Notación en un diagrama de clases

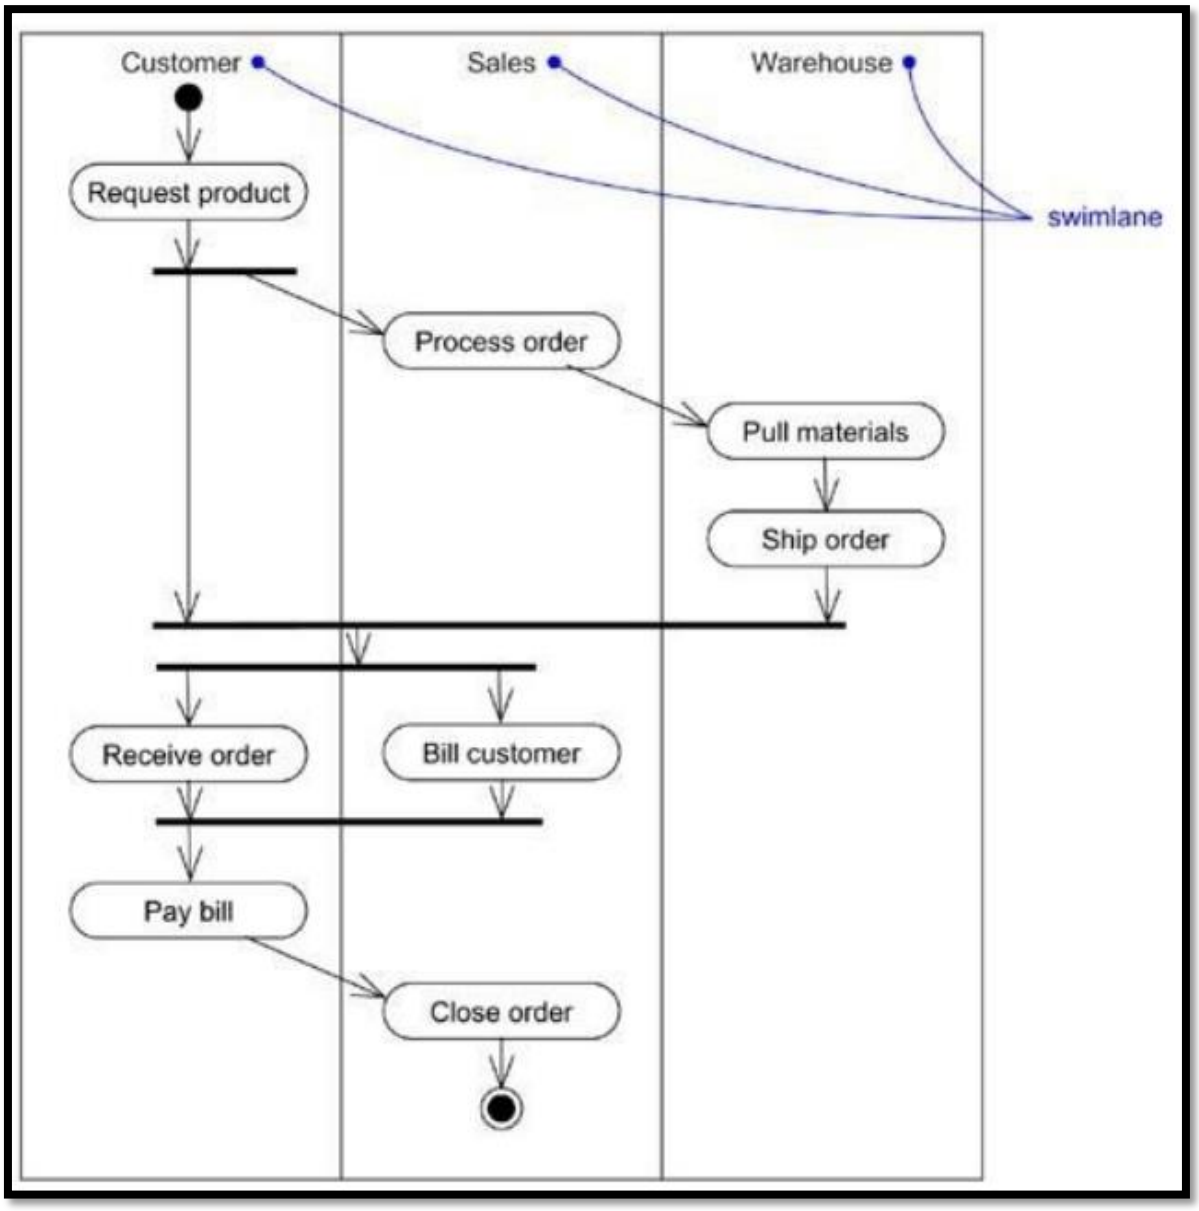


Fuente. Tomado de. (Cubero 2020, p. 6).

2.1.4.4 Diagrama de Actividades

Se encarga de representar las actividades que se definen como “Una actividad es una serie de acciones. Una acción consiste en asignar un valor a un atributo, crear o destruir un objeto, efectuar una operación” (Debrauwer y Van Der Heyde, 2020, p. 163).

Figura 2.11 Diagrama de Actividades



Fuente. Tomado de. (Aurelio 2024, p. 35).

2.1.4.4.1 Encadenamiento De Actividades

Estos se refieren a un vínculo entre dos actividades, de acuerdo con Debrauwer y Van Der Heyde (2020) “Un encadenamiento de actividades es un vínculo orientado entre dos actividades. Puede traspasarse cuando concluye la actividad inicial, lo que conduce a la activación de la actividad final” (p. 163).

2.1.4.4.2 Particiones

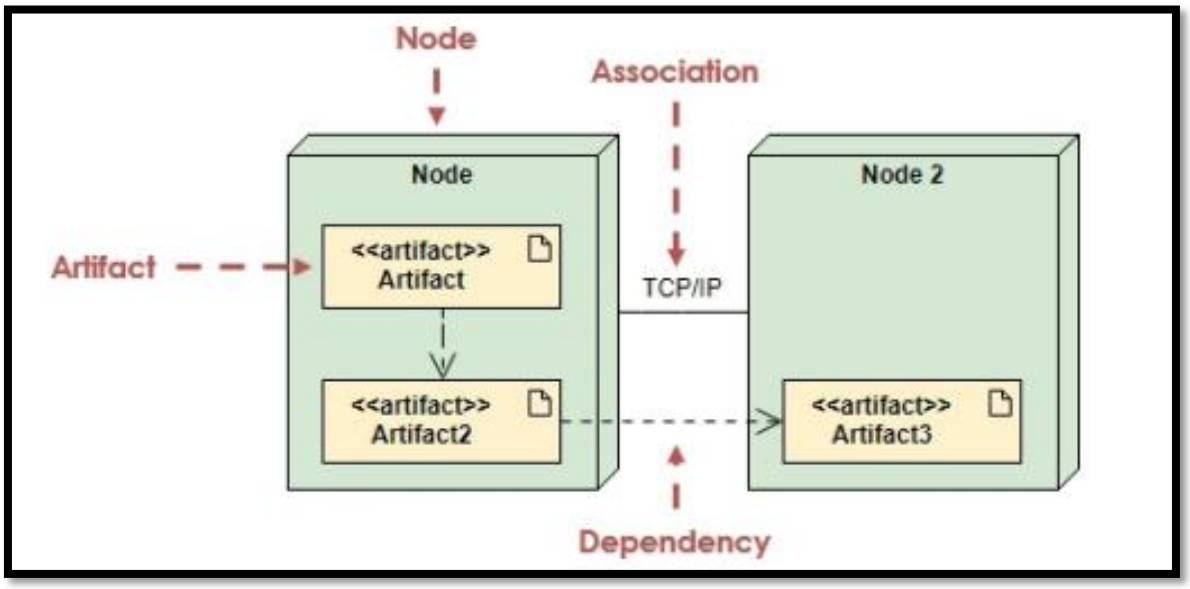
Estas dividen a los objetos para tener un mejor orden, este diagrama se divide en particiones donde corresponde un objeto que es el encargado de realizar la actividad que pertenece a esta calle (Debrauwer y Van Der Heyde, 2020).

2.1.4.4.3 Diagrama De Despliegue

Este es el último diagrama realizado y se encarga de representar la arquitectura física del sistema mediante distintos nodos que ejecutan partes del sistema o piezas de software. Otros autores nos dicen lo siguiente:

> El diagrama de despliegue describe la arquitectura física del sistema. Está compuesto de nodos. Un nodo es una unidad material capaz de recibir y de ejecutar elementos de software. La mayoría de nodos son ordenadores. Los vínculos físicos entre nodos también pueden describirse en el diagrama de despliegue, corresponden a las ramas de la red.
>
> Los nodos contienen elementos de software en su forma física, conocida como artefact. Los archivos ejecutables, las bibliotecas compartidas y los scripts son ejemplos de formas físicas de elementos de software. (Debrauwer y Van Der Heyde, 2020, p. 191)

Figura 2.12 Diagrama de Despliegue



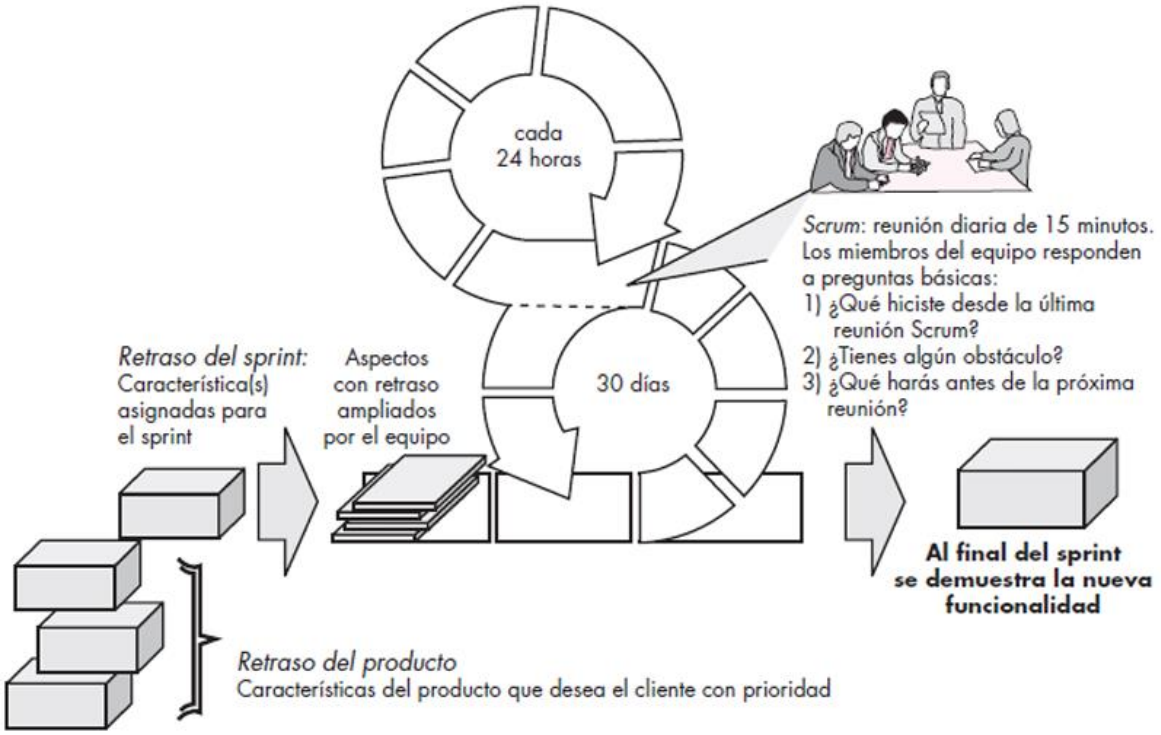
Fuente. Tomado de. (Aurelio 2024, p. 53).

2.1.5 METODOLOGÍA DE DESARROLLO DE SOFTWARE

2.1.5.1 SCRUM

La metodología Scrum se define para guiar las actividades a tiempo real, Celi et al., (2023) lo definen como “Los principios Scrum son congruentes con el manifiesto ágil y se utilizan para guiar actividades de desarrollo dentro de un proceso de análisis que incorpora las siguientes actividades estructurales: requerimientos, análisis, diseño, evolución y entrega” (p. 30).

Figura 2.13 Esquema de la Metodología Scrum



Fuente. Tomado de Celi et al., (2023).

2.1.5.1.1 Actores

Dentro del marco de trabajo Scrum, se identifican roles y elementos fundamentales para su correcta ejecución. De acuerdo con Pressman y Maxim (2021), los actores o equipo de scrum conforman un grupo interdisciplinario y autoorganizado que consta de tres roles específicos:

- Propietario del producto (Product Owner): Es la persona encargada de establecer y ordenar las prioridades de los requerimientos o características del producto que aportan valor de negocio para el cliente. Es el responsable de gestionar la lista de

objetivos y es el único con autoridad para decidir si un incremento es aceptado o si un sprint debe cancelarse antes de tiempo (p. 43).

- Maestro Scrum (Scrum Master): Sirve como facilitador para todos los miembros del equipo. Es el responsable de llevar a cabo las reuniones diarias, guiar el proceso y eliminar los obstáculos o impedimentos técnicos que los miembros del equipo identifiquen para que puedan completar sus tareas (p. 44).
- Equipo de desarrollo (Development Team): Es un grupo pequeño y autoorganizado (generalmente de tres a seis personas) responsable de seleccionar los requerimientos, decidir cómo se ejecutarán y llevar a cabo las tareas de ingeniería de software (programación y pruebas) necesarias para entregar un incremento funcional al final de cada sprint (p. 44).

2.1.5.1.2 Artefactos

El proceso genera una serie de Artefactos de Scrum, los cuales representan el trabajo y el valor generado en el proyecto, diseñados para maximizar la transparencia de la información clave (Pressman y Maxim, 2021):

- Product Backlog: Es una lista con prioridades de los requerimientos o características del producto. Es un documento dinámico que nunca está completo, ya que evoluciona constantemente para satisfacer las nuevas necesidades de las partes interesadas (p. 43).
- Sprint Backlog: Es el subconjunto de aspectos de la lista de objetivos principales que el equipo de desarrollo selecciona y se compromete a completar durante el sprint activo actual. Una vez iniciado el sprint, no se pueden agregar nuevas características a esta lista (p. 44).
- Incremento: Es la unión de todos los aspectos de la lista de objetivos completados durante el sprint actual, integrados con los incrementos de los sprints anteriores. Al final del sprint, este incremento debe estar terminado y listo para ser demostrado al propietario del producto (p. 44).

2.1.5.1.3 Eventos

Para sincronizar el trabajo y asegurar la transparencia y la inspección continua, el marco de trabajo establece una serie de eventos de Scrum. Según Pressman y Maxim (2021), estos eventos operan dentro de un periodo de tiempo asignado y comprenden:

- El Sprint: Es el evento contenedor de todos los demás. Consiste en un periodo de desarrollo de prototipos incrementales que, por lo general, tiene una duración fijada de dos a cuatro semanas. Durante el sprint, el equipo adapta y modifica el trabajo necesario para entregar el incremento (p. 43).
- Sprint Planning: Se realiza antes de comenzar cada sprint. En ella, el propietario del producto indica su meta y el equipo de desarrollo selecciona los aspectos de la lista de objetivos que se pueden entregar dentro del tiempo asignado, definiendo así el trabajo necesario para lograrlo (p. 44).
- Daily Scrum: Es un evento breve, típicamente de 15 minutos, programado al inicio de cada día de trabajo para que los miembros del equipo sincronicen sus actividades. Se responden tres preguntas clave: qué se hizo desde la última reunión, qué obstáculos se encontraron y qué se planea lograr para la próxima reunión (p. 44).
- Sprint Review: Ocurre al final del sprint. Su actividad principal es la demostración del incremento de software completado a las partes interesadas y al propietario del producto, quien puede aceptar el incremento o proveer retroalimentación para la siguiente ronda de planeación (p. 45).
- Sprint Retrospective: Es una reunión que se lleva a cabo después de la revisión y antes del siguiente sprint. El maestro Scrum conduce esta sesión para que el equipo discuta qué se hizo bien, qué podría mejorarse y a qué mejoras se comprometerán en el siguiente ciclo, adaptando así sus prácticas para ser más efectivos (p. 45).

2.1.6 METODOLOGÍA DE DESARROLLO DE MODELO DE IA

2.1.6.1 CRISP-DM

Esta será la metodología seleccionada dado que según Sánchez y Pérez, (2021):

> Es un modelo de referencia que describe de forma general las fases, tareas generales y salidas de un proyecto de Data Mining en general. Por otro lado, la guía del usuario proporciona información a detalle sobre la aplicación del modelo a proyectos de Data Minning específicos, se proporcionan guías y listas de cotejo sobre las actividades y tareas correspondientes a cada fase. De esta manera se estructura el ciclo de vida de un proyecto en seis fases, que interactúan entre ellas de forma iterativa durante el desarrollo del mismo. (p. 4)

Y lo comprenden las siguientes fases:

2.1.6.1.1 Comprensión del Negocio

Esta es la fase de inicio, Sanchéz y Pérez, (2021) la describen como:

> Es la fase de inicio, se identifica el objetivo del negocio, cual es problema y que se busca resolver las tareas, propósitos y requisitos del proyecto desde una perspectiva de negocio, que se traducen en objetivos técnicos para plasmarlos en un plan del proyecto. (p. 4)

2.1.6.2 Comprensión de los Datos

Fase importante para comprender el problema, en esta fase se realiza el reconocimiento básico de los datos, Sanchéz y Pérez, (2021) nos exponen:

> Se establece el primer acercamiento para familiarizarse con el problema, en esta fase de recolectan los datos iniciales, se describe su significado, se procede a explorar los datos, es decir aplicar pruebas estadísticas básicas e identificar la calidad de los datos y plantear las hipótesis. (p. 4)

2.1.6.3 Preparación de Datos

Esta fase se describe como: “Después de la recolección inicial, se seleccionan, limpian, formatean e integran los datos” (Sánchez y Pérez, 2021, p.4).

2.1.6.4 Modelado

“En esta fase se elige la técnica en función de: disposición de datos, conocimiento de la técnica, pertinencia con el problema y cumplir con los requisitos. Se realiza un plan de prueba para generar el modelo y evaluarlo” (Sánchez y Pérez, 2021, p.4).

2.1.6.5 Evaluación

“Se evalúan los resultados, se revisa el proceso para identificar deficiencias. Si el modelo generado es válido en función de los criterios establecidos en la fase anterior, se procede a la implementación del modelo” (Sánchez y Pérez, 2021, p.4).

2.1.6.6 Implementación

Según nos describen Sánchez y Pérez, (2021) “En esta fase se propone contar con estrategias para monitorear y mantener el modelo” (p. 4).

2.1.7 HERRAMIENTAS DE DESARROLLO

2.1.7.1 Programación Web

En relación con las tecnologías de desarrollo web. Celi et al., (2023) afirman que:

> En el desarrollo de proyectos Web, la generación del contenido de las páginas se lleva a cabo generalmente utilizando un conjunto de tecnologías en las que se integran tecnologías dedicadas, por un lado, a la generación del contenido estático, y por otro, tecnologías encaminadas a generar el contenido dinámico de las páginas Web.
>
> Cuando se habla de contenido estático se hace referencia al contenido de las páginas Web, el cual se presenta de forma estática, invariante a las acciones que realiza el usuario, y cuyo objetivo primordial es presentar datos al usuario, los cuales normalmente no cambian con el paso del tiempo. (p. 3)

Con esta introducción a la programación web se nos hará más fácil seguir entendiendo los conceptos más complejos.

2.1.7.2 HTML (Hyper Text Markup Language)

En cuanto al origen y evolución de HTML, Celi et al., (2023) afirma que “HTML fue desarrollado originalmente por Tim Berners-Lee mientras estaba en el CERN, y popularizado por el navegador Mosaic desarrollado en NCSA. Durante el transcurso de la década de 1990 proliferó con el crecimiento explosivo de la Web” (p. 9). La primera versión de HTML fue en 1990 y hoy en día estamos manejando HTML 5, “Lo que hace el estándar HTML5 es especificar qué marcas deben utilizarse para escribir un documento web y qué significa cada una de ellas. De esta forma, cualquier navegador sabrá cómo interpretarlas” (Celi et al., 2023, p 10).

Como indica Wójcik et al. (2021), los sitios web son usualmente creados en editores y guardados en archivos de texto, al momento de cargar un archivo HTML, el navegador interpreta etiquetas que son colocadas en estos archivos con el fin de mostrar la información. Estas etiquetas pueden tener atributos y estos a su vez valores, como se ve en la figura.

2.1.7.3 CSS (Cascading Style Sheets)

De acuerdo con Hernández y Baquero (2020):

> CSS (Cascading Style Sheets), o también “hojas de estilo en cascada”. La primera versión de CSS fue publicada a finales del año 1996. A su vez, fue logrando popularidad y aceptación hasta llegar a la versión 2.1, estándar actual que brinda compatibilidad con la mayoría de los navegadores existentes en el mercado. (p. 70)

“A partir del año 2005, se comenzó a definir el sucesor de esta versión, al cual se le conoce como CSS3 o Cascading Style Sheets Level” (Hernández y Baquero, 2020, p. 70).

2.1.7.4 JavaScript

En palabras de Hernández y Baquero (2020):

> JavaScript es un lenguaje interpretado, basado en objetos que permite incluir macros en páginas web. Estas macros se ejecutan en el computador, en páginas web del cliente, y no en el servidor (algo muy interesante, porque los servidores web están sobrecargados con el procesamiento propio de la aplicación, mientras que los computadores de los usuarios no suelen estarlo, pues solo realizan las peticiones y esperan las respuestas del lado del servidor). (p. 108)

2.1.7.5 El Lenguaje de Programación Rust

Rust es uno de los lenguajes de programación mas usados por su velocidad y su control profundo en general. Muñoz, (2024) nos expone:

> Rust emerge en la escena de la programación como un lenguaje que aborda desafíos significativos y omnipresentes en el ámbito de la computación. Su oferta de un control profundo sobre el rendimiento del hardware, combinada con garantías integrales de seguridad de la memoria, lo convierte en un candidato idóneo para diversas aplicaciones. Este abanico de posibilidades abarca desde sistemas embebidos hasta servidores web de alto rendimiento y, particularmente, proyectos en el campo del Machine Learning (ML).
>
> Rust no es simplemente otro lenguaje en el ecosistema de la programación; es el resultado de una meticulosa ingeniería del lenguaje que aprovecha más de una década de avances en diseño y teoría de lenguajes de programación. Adopta las mejores prácticas de lenguajes predecesores como C++ y Haskell, y además introduce innovaciones que buscan resolver problemas de acceso no seguro a la memoria y dificultades en la concurrencia. (pp. 21-22)

2.1.7.5.1 Polars

Es una de las bibliotecas de Rust para el manejo de DataFrames, Muñoz, (2024) profundiza al respecto:

> Las bibliotecas como `reqwest` y `scraper` facilitan la obtención de datos, mientras que `polars` es excelente para su almacenamiento y manipulación. Sin embargo, se deben considerar éticamente las fuentes de los datos y asegurarse de que se almacenen y validen adecuadamente. (p. 121)

2.1.7.5.2 Leptos

De acuerdo con la documentación oficial del Leptos Team (2026), Leptos es un framework web de pila completa (full-stack), isomórfico y de alto rendimiento diseñado para el lenguaje Rust. Su arquitectura permite la creación de interfaces de usuario declarativas con una reactividad que optimiza la actualización de componentes en el navegador.

2.1.7.5.3 Axum

De acuerdo con la documentación oficial del Tokio Team (2026), Axum es un framework web enfocado en la ergonomía y la modularidad, diseñado específicamente para integrarse con el ecosistema asíncrono de Rust. A diferencia de otros frameworks tradicionales, Axum aprovecha el sistema de tipos del lenguaje para garantizar la seguridad en el manejo de peticiones y respuestas.

2.1.7.6 WebAssembly

WebAssembly es una tecnologia fundamental en la actualidad, Sletten, (2024) nos dice sobre WebAssembly:

> En esta visión, WebAssembly se centra en la intersección del desarrollo de software, la web, su historia y cómo ofrece funcionalidad en un espacio geográficamente distribuido. Con el tiempo, la idea se ha ampliado drásticamente más allá de este punto de partida para imaginar una plataforma computacional ubicua, segura y de alto rendimiento que afecte a casi todos los aspectos de nuestra vida profesional como tecnólogos. WebAssembly tendrá un impacto en los mundos del desarrollo web del lado del cliente, las aplicaciones de escritorio y empresariales, la funcionalidad del lado del servidor, la modernización del legado, los juegos, la educación, la computación en la nube, las plataformas móviles, los ecosistemas del Internet de las Cosas (IoT), las iniciativas sin servidor y de microservicios, y mucho más. (p. 1)

2.1.7.7 WEBASSEMBLY Y RUST

Para entender a Rust y a WebAssembly debemos ver como se integran, Sletten, (2024) nos lo explica de la siguiente manera:

> WebAssembly. Este es el primer gran paso hacia un lenguaje diferente. Rust es un lenguaje moderno con una ética moderna. Proporciona un buen rendimiento en tiempo de ejecución con una red de seguridad que sería casi imposible engendrar como una ocurrencia tardía. Dado el importante papel que C y C++ siguen

> desempeñando en los fallos, defectos y exploits de malware a los que nos enfrentamos a diario, disponer de un lenguaje de sistemas rápido y seguro es una mejora material. Tras un largo periodo como favorito de la comunidad de código abierto, estas ventajas han empezado a ser obvias para los desarrolladores comerciales, y el interés por Rust crece día a día.

2.1.7.8 Visual Studio Code

"Microsoft Visual Studio Code es un editor de código gratuito, eficaz y ligero para Windows, macOS y Linux. Basado en código abierto, es muy personalizable con más de 25 000 extensiones, para cada desarrollador y cada lenguaje de programación" (Microsoft, 2026, parr. 1).

2.1.7.9 Micro

Micro es otro editor de texto que de acuerdo con Micro Editor, (2026):

> Micro es un editor de texto para terminal que busca ser fácil de usar e intuitivo, aprovechando al mismo tiempo todas las capacidades de las terminales modernas. Se presenta como un único binario estático, completo y sin dependencias, y puedes descargarlo y usarlo ahora mismo.
>
> Como su nombre indica, micro pretende ser una especie de sucesor del editor nano, ya que es fácil de instalar y usar en caso de necesidad, pero también pretende ser agradable de usar a tiempo completo, tanto si trabajas en la terminal porque la prefieres (como yo) como si lo necesitas (a través de ssh). (parr. 1-2)

2.1.7.10 Git

> La principal diferencia entre Git y cualquier otro VCS (incluyendo Subversion y sus amigos) es la forma en la que manejan sus datos. Conceptualmente, la mayoría de los otros sistemas almacenan la información como una lista de cambios en los archivos. Estos sistemas (CVS, Subversion, Perforce, Bazaar, etc.) manejan la información que almacenan como un conjunto de archivos y las modificaciones hechas a cada uno de ellos a través del tiempo. (Chacon y Straub, 2026, p. 14)

2.1.7.11 GitHub

> GitHub es el mayor proveedor de alojamiento de repositorios Git, y es el punto de encuentro para que millones de desarrolladores colaboren en el desarrollo de sus proyectos. Un gran porcentaje de los repositorios Git se almacenan en GitHub, y muchos proyectos de código abierto lo utilizan para hospedar su Git, realizar su

> seguimiento de fallos, hacer revisiones de código y otras cosas. Por tanto, aunque no sea parte directa del proyecto de código abierto de Git, es muy probable que durante tu uso profesional de Git necesites interactuar con GitHub en algún momento. (Chacon y Straub, 2026, p. 166)

2.1.7.12 PlantUML

PlantUML, (2020) PlantUML es un proyecto Open Source (código abierto) que permite escribir rápidamente diagramas de secuencia, casos de uso, clases, objetos, actividades, componentes, despliegue, estados, entre otros, utilizando un lenguaje simple e intuitivo.

2.1.7.13 Draw.io

Draw.io es una herramienta para diagramación, según draw.io Ltd, (2026)

> Draw.io es la aplicación de diagramación más utilizada del mundo y su uso e implementación son gratuitos.
>
> Desde 2005, hemos estado desarrollando software de diagramación con una misión: proporcionar software de diagramación gratuito y de alta calidad para todo el mundo. (parr. 1-2)

2.1.7.14 Docker

De acuerdo con Sánchez (2026) “Docker es una plataforma de código abierto diseñada para facilitar la creación, implementación y ejecución de aplicaciones en contenedores” (p. 1).

2.1.7.15 Microsoft Azure

> Microsoft Azure es una plataforma de informática en la nube de Microsoft que ofrece más de 200 productos y servicios en una red global de centros de datos, diseñada para respaldar la estrategia empresarial, la administración de infraestructura y el desarrollo de soluciones tecnológicas escalables. (Microsoft, 2026)

2.1.7.16 GNS3

> GNS3 (Graphical Network Simulator) es una plataforma de software de código abierto que permite la emulación y simulación de redes complejas, combinando dispositivos virtuales y reales para diseñar, probar y configurar topologías de red en un entorno de laboratorio. (GNS3 Technologies, 2026)

2.1.7.17 Bash

De acuerdo con Ollé (2020):

> Bash (Bourne-again Shell) es una de las shells o línea de comandos más populares que hay en la mayoría de distribuciones GNU/Linux.
>
> Bash incluye mejoras propias, pero también tiene características de otras shells populares, como la Korn Shell y la C Shell, y, a su vez, es compatible con la de su predecesora, Bourne Shell. (p. 5)

2.1.7.18 Firebase Cloud Messaging

"Firebase Cloud Messaging (FCM) es una solución de mensajería multiplataforma que te permite enviar mensajes de forma fiable" (Google, 2026).

2.1.8 ESTIMACIÓN DE COSTOS

De acuerdo con Briano (2023):

> La estimación de un proyecto es quizá la parte tarea más compleja que debe desarrollar el encargado de gestionarlo. En determinadas industrias, en función de los estándares y la experiencia, existen tablas estimativas que facilitan la tarea. Hay tiempos estimados de cuanto lleva construir una casa; las automotrices saben cuánto les lleva el proceso de fabricación de un vehículo, pero… ¿existe tal cosa en el software? (p. 173)

Según Briano (2023) tenemos dos tecnicas para estimar el costo de un software, las tecnicas basadas en experiencia y los modelos algoritmicos (donde entra COCOMO) sin embargo menciona que existen factores que afectan a estas tecnicas: Complejidad, tamaño, incertidumbre e información historica.

Se deben estimar tres cosas:

2.1.8.1 Recursos Humanos

> La actividad desarrollo de software es una actividad que depende fundamentalmente de los recursos humanos y de su capacidad intelectual. Será necesario contratar líderes de proyecto, analistas, diseñadores, programadores, testar, implementadores, especialistas en riesgo y seguridad. Si el proyecto es más grande, aparecerán seguramente muchas más funciones (analistas de experiencia de usuario, arquitecto se software, analistas de calidad, entre otros). Para cada uno de los recursos necesarios deberá estimarse la cantidad, los conocimientos requeridos y donde estarán ubicados físicamente. (Briano, 2023, p. 174)

2.1.8.2 Recursos Ambientales

En este apartado acuñaremos la definición de Briano, (2023):

> La actividad desarrollo de software es una actividad que depende fundamentalmente de los recursos humanos y de su capacidad intelectual. Será necesario contratar líderes de proyecto, analistas, diseñadores, programadores, testar, implementadores, especialistas en riesgo y seguridad. Si el proyecto es más grande, aparecerán seguramente muchas más funciones (analistas de experiencia de usuario, arquitecto se software, analistas de calidad, entre otros). Para cada uno de los recursos necesarios deberá estimarse la cantidad, los conocimientos requeridos y donde estarán ubicados físicamente. (p. 174)

2.1.8.3 Componentes a Desarrollar

> Será necesario construir nuevos componentes, podrán reutilizarse componentes ya desarrollados (por ejemplo, el componente que gestiona el login de usuarios, o tablas ya cargadas o la documentación de ciertas funcionalidades), o también modificar alguno y adaptarlo al nuevo desarrollo. También existe la posibilidad de comprar o conseguir externamente componentes completos e incluirlos en el nuevo sistema, por ejemplo, un carrito de compras o un botón de pago. (Briano, 2023, p. 175)

2.1.8.4 Estimación en Metodologías Ágiles

De acuerdo con Briano (2023):

> A diferencia de los modelos tradicionales, en las metodologías ágiles no se presupuesta la totalidad del software al inicio del proyecto debido a la naturaleza evolutiva de los requerimientos. Briano (año) establece que un costeo preciso requiere un plan detallado, por lo que en entornos ágiles la estimación se adapta a entregas periódicas de software funcional, priorizando la flexibilidad

Briano (2023) también nos propone estimar empleando técnicas de valorización calculando el costo de los recursos involucrados y estimar los costos por sprint en lugar de estimarlos de todo el proyecto.

2.1.8.5 Puntos de Función

Esta es una de las formas de estimar un proyecto de software, según Pressman y Maxim, (2021):

> Puesto que la estimación de un proyecto solo es tan buena como la estimación del tamaño del trabajo a realizar, el dimensionado del software representa su primer

desafío como planeador. En el contexto de la planeación de proyectos, el tamaño se refiere a un resultado cuantificable del proyecto de software. Si se adopta un enfoque directo, el tamaño puede medirse en líneas de código (LOC). Si se elige un enfoque indirecto, el tamaño se representa como puntos de función (FP). Para estimar el tamaño se considera el tipo de proyecto y su dominio de aplicación, la funcionalidad entregada (es decir, el número de puntos de función), el número de componentes (o casos de uso) a entregar y la medida en que un conjunto de componentes existentes debe modificarse para el nuevo sistema. (p. 512)

2.1.8.5.1 Ejemplo de Uso

La descomposición para la estimación basada en FP se enfoca en los valores del dominio de información en vez de las funciones del software. [...] Para calcular el conteo total necesario en la ecuación de FP:

$$\text{FP}_{estimado} = \text{conteo total} \times \left[0.65 + 0.01 \times \sum(Fi)\right]$$

Para los fines de esta estimación, se asume que el factor de ponderación de complejidad será un promedio. [...] Para calcular un valor para $\sum(Fi)$, cada uno de los 14 factores de ponderación de complejidad enumerados [...] se califica con un valor entre 0 (no importante) y 5 (muy importante). La suma de estas calificaciones para los factores de complejidad $\sum(Fi)$ es de 52. Entonces, el valor del factor de ajuste es 1.17:

$$\left[0.65 + 0.01 \times \sum(Fi)\right] = 1.17$$

Por último, se deriva el número estimado de FP:

$\text{FP}_{estimado} = \text{conteo total} \times [0.65 + 0.01 \times \sum(Fi)] = 375$ » (Pressman y Maxim, 2021, pp. 514-515)

2.1.9 ASEGURAMIENTO DE CALIDAD

“En el sentido más general, podemos defi nir la calidad del software así: un proceso de software efectivo, aplicado de una forma que cree un producto útil, el cual ofrezca un valor cuantifi cable para quienes lo producen y quienes lo utilizan.” (Pressman y Maxim, 2021, p. 312).

2.1.9.1 Pruebas de Caja Blanca

Este tipo de pruebas ayudan a derivar casos de prueba, según Pressman y Maxim, (2021):

> Las pruebas de caja blanca, algunas veces conocidas como pruebas de caja de cristal o pruebas estructurales, son una filosofía de diseño de casos de prueba que utiliza la estructura de control descrita como parte del diseño a nivel de componentes para derivar casos de prueba. (p. 383)

2.1.9.1.1 Pruebas de Ruta Base

> El método de ruta base permite al diseñador de los casos de prueba derivar una medida de complejidad lógica de un diseño procedimental y usar esta medida como guía para definir un conjunto base de rutas de ejecución. Se garantiza que los casos de prueba derivados para ejercer el conjunto base ejecutarán cada instrucción en el programa al menos una vez durante la prueba. (Pressman y Maxim, 2021, p. 384).

2.1.9.1.2 Pruebas de Estructura de Control

> Es una de varias técnicas para las pruebas de estructura de control. Aunque las pruebas de ruta base son simples y muy efectivas, no son suficientes por sí solas. En esta sección analizaremos otras variaciones de las pruebas de estructura de control. Estas amplían la cobertura de las pruebas y mejoran la calidad de las pruebas de caja blanca. (Pressman y Maxim, 2021, p. 386).

2.1.9.2 Pruebas de Caja Negra

De acuerdo con Pressman y Maxim, (2021) este otro tipo de pruebas son:

> Las pruebas de caja negra, conocidas también como pruebas de comportamiento o funcionales, se enfocan en los requerimientos funcionales del software. Esto es, las técnicas de pruebas de caja negra nos permiten derivar conjuntos de condiciones de entrada que empleen todos los requerimientos funcionales de un programa. Las pruebas de caja negra no son una alternativa para las técnicas de caja blanca. Más bien, son un enfoque complementario que muy probablemente descubra una clase distinta de errores que los métodos de caja blanca. (p. 387)

2.1.9.2.1 Pruebas de Interfaz

“Se usan para comprobar que el componente del programa acepte la información que recibe en el orden y con los tipos de datos apropiados, y que devuelva la información en el orden y formato de datos apropiados” (Pressman y Maxim, 2021, p. 388).

2.1.9.2.2 Particionamiento de Equivalencias

Pressman y Maxim, (2021) “El particionamiento de equivalencias es un método de prueba de caja negra que divide el dominio de entrada de un programa en clases de datos a partir de las cuales pueden derivarse casos de prueba” (p. 389).

2.1.9.2.3 Análisis de Valores Límite

“El análisis de valores límite es una técnica de diseño de casos prueba que complementa el particionamiento de equivalencias. En vez de seleccionar cualquier elemento de una clase de equivalencias” (Pressman y Maxim, 2021, p. 389).

2.1.9.3 Pruebas de Integración

Este otro tipo de pruebas se basan en verificar que todo funcione respecto a las interfaces, Pressman y Maxim, (2021) lo describen:

> Las pruebas de integración son una técnica sistemática para construir la arquitectura de software, mientras que al mismo tiempo se realizan pruebas para descubrir errores aso ciados con las interfaces. El objetivo es tomar los componentes a los que se les realizó la prueba unitaria y crear una estructura de programa regida por el diseño. (p. 398)

2.1.9.4 Pruebas de Validación

“Podemos definir la validación de muchas formas, pero una definición simple (aunque cruda) es que la validación tiene éxito cuando el software funciona de una forma que el cliente pueda esperar razonablemente” (Pressman y Maxim, 2021, p. 407).

2.1.9.5 Pruebas de Contenido

Esta es una prueba descrita para aplicaciones web, Pressman y Maxim, (2021) lo abarcan de la siguiente manera:

> Tienen tres objetivos importantes: (1) descubrir errores sin tácticos (como errores tipográficos o de gramática) en documentos basados en texto, re presentaciones gráficas y otros medios; (2) descubrir errores semánticos (es decir, errores en la precisión o integridad de la información) en cualquier objeto de contenido que se presente mientras se realiza la navegación y (3) encontrar errores en la organización o estructura del contenido que se presenta al usuario final. (p. 420)

2.1.9.6 Pruebas de Interfáz

Otra de las pruebas web según Pressman y Maxim, (2021) son “Las pruebas de interfaz ejercitan los mecanismos de interacción y validan los aspectos estéticos de la interfaz de usuario” (p. 421).

2.1.9.7 Pruebas de Navegación

“El trabajo de las pruebas de navegación es (1) asegurar que los mecanismos que permiten al usuario recorrer la WebApp sean todos funcionales y (2) validar que cada NSU pueda ser realizada por la categoría de usuario apropiada” (Pressman y Maxim, 2021, p. 422).

2.1.9.8 Pruebas de Seguridad

“Las pruebas de seguridad intentan verifi car que los mecanismos de protección integrados en un sistema realmente lo protejan de una penetración inapropiada” (Pressman y Maxim, 2021, p. 423).

2.1.9.9 Pruebas de Rendimiento

> Las pruebas de rendimiento se usan para descubrir problemas de rendimiento que pueden resultar de una falta de recursos del lado servidor, un ancho de banda de red inadecuado, capacidades de bases de datos inadecuadas, capacidades del sistema operativo defectuosas o débiles, una funcionalidad de la WebApp mal diseñada y otros aspectos de hardware o software que puedan conducir a un rendimiento degradado del cliente-servidor. El propósito es doble: (1) entender cómo responde el sistema en cuanto aumenta la carga (es decir, número de usuarios, número de transacciones o volumen de datos total) y (2) recolectar métricas que conduzcan a modifi caciones del diseño para mejorar el rendimiento. (Pressman y Maxim, 2021, p. 425).

2.1.10 SEGURIDAD DEL SISTEMA

Con la creciente interconectividad global y el valor inherente de los datos corporativos, la protección de las arquitecturas de red demanda esquemas defensivos profundos fundamentados en teoría criptográfica y en topologías avanzadas.

2.1.10.1 Tríada De Seguridad De La Información Y Defensa En Profundidad

La arquitectura fundamental de ciberseguridad se cimenta irrefutablemente sobre el axioma analítico de la Tríada CIA: Confidencialidad, Integridad y Disponibilidad (Availability). La Confidencialidad garantiza que la información en estado de reposo y en tránsito sea ilegible y esté ocluida para cualquier entidad no autenticada, aplicando para ello la robustez de los

cifrados simétricos (AES-256) y asimétricos (RSA, Curvas Elípticas), respaldados por mecanismos de autenticación y controles de acceso basados en roles (RBAC). La Integridad protege heurísticamente los datos vitales contra alteraciones, modificaciones no autorizadas, ataques de inyección (SQLi) o corrupción fortuita. Para validarlo de manera criptográfica, se emplean algoritmos hash (como SHA-3) y firmas digitales. Finalmente, la Disponibilidad asegura incondicionalmente el acceso sostenido e ininterrumpido a la infraestructura y datos por parte de los usuarios legítimos, lo cual requiere topologías con redundancia extrema, balanceo geométrico de carga y algoritmos mitigantes frente a ataques volumétricos de Denegación de Servicio Distribuido (DDoS).

El modelo doctrinario de "Defensa en Profundidad" (Defense in Depth) es una estrategia de ciber-resiliencia holística y multinivel que impone establecer capas concéntricas y superpuestas de medidas defensivas y obstáculos de seguridad (segmentación de redes, hardening de hosts, análisis estático de aplicaciones de software, políticas estrictas de control de identidad y prevención de fuga de datos o DLP). Este modelo dictamina que el fracaso inevitable de una medida perimetral o un único control de seguridad se vea inmediatamente absorbido y mitigado por la siguiente capa estructural de protección, frenando efectivamente la propagación del compromiso.

2.1.10.2 Hashing Criptográfico de Contraseñas

En este algoritmo llevamos una función con poca entropía haciendo uso de la sal, mas específicamente, Lucena (2022) la define cómo:

> La función KDF se suele usar entonces para generar un valor que se almacena, junto con la sal, y que permitirá verificar la contraseña en el futuro sin guardarla explícitamente. Puesto que los posibles valores para la contraseña serían relativamente pocos, un atacante podría hacer una búsqueda exhaustiva, con un coste computacional dado por la entropía inicial del conjunto. Para aumentar la dificultad de este ataque por la fuerza bruta, haciendo que en la práctica sea equivalente a una búsqueda dentro un espacio de valores mucho mayor, se emplean funciones que sean deliberadamente exigentes desde el punto de vista computacional. (p. 273)

2.1.10.3 Comparación en Tiempo Constante

Se refiere a una técnica usada para mejorar el control de accesos sin exponer ningún tipo de información, otros autores la definen como:

> En contextos que afectan a la seguridad, incluso pequeñas variaciones en la sincronización pueden ser aprovechadas por los atacantes para inferir indirectamente ciertos detalles sobre el funcionamiento interno del producto. Por ejemplo, en algunos algoritmos criptográficos, los atacantes pueden usar las diferencias de tiempo para inferir ciertas propiedades de una clave privada, facilitando así su adivinación. Estas discrepancias temporales constituyen, en la práctica, un canal lateral de temporización. (MITRE Corporation, 2026, parr. 2)

2.1.10.4 Tokens Opácos de Sesión

SecureAuth Corporation (2026) en su documentación oficial los definen como:

> El token opaco es una cadena de caracteres única y aleatoria emitida por el servidor de autorización. Es uno de los formatos posibles para los tokens de acceso o de actualización. El token opaco no transmite información identificativa del usuario, por lo que el servidor de recursos no puede tomar decisiones de autorización basándose únicamente en él. El token opaco contiene un identificador que apunta a la información almacenada en el servidor de autorización. Para validar el token y recuperar la información del token y del usuario, el servidor de recursos llama al servidor de autorización y solicita la introspección del token.
>
> Con los tokens opacos, puede ocultar información de identificación personal (PII), evitar que se compartan las credenciales y limitar el tamaño de los encabezados de la solicitud (para evitar el rechazo de solicitudes sobrecargadas). (parr. 4-5)

2.1.10.5 Firma Digital

Una firma digital ayuda al control de integridad, Lucena (2022) nos detalla:

> Una firma digital es una secuencia de bits que se añade a una pieza de información cualquiera, y que permite garantizar su autenticidad de forma independiente del proceso de transmisión, tantas veces como se desee. Presenta una analogía directa con la firma manuscrita, y para que sea equiparable a esta última debe cumplir las siguientes propiedades.
>
> Va ligada indisolublemente al mensaje. Una firma digital válida para un documento no puede ser válida para otro distinto.

> Sólo puede ser generada por su legítimo titular. Al igual que ca da persona tiene una forma diferente de escribir, y que la escritura de dos personas diferentes puede ser distinguida mediante análisis caligráficos, una firma digital sólo puede ser construida por la persona o personas a quienes legalmente corresponde.
>
> Es públicamente verificable. Cualquiera puede comprobar su autenticidad en cualquier momento, de forma sencilla (p. 303)

2.2 MARCO CONCEPTUAL

2.2.1 INTELIGENCIA ARTIFICIAL

La inteligencia artificial es un campo muy amplio que ha crecido mucho en los últimos años. Arán (2022) afirmó que:

> La inteligencia artificial (IA) es un campo de las ciencias de la computación en el que, mediante el diseño de diferentes algoritmos, se busca que las máquinas adopten comportamientos propios de los seres humanos, tales como el aprendizaje o la toma de decisiones. Así, se pueden resolver problemas que requieran un alto rendimiento para procesar grandes cantidades de datos, y, al mismo tiempo, se puede mejorar la manera de procesarlos. (p. 1)

Desde un enfoque mas reciente Briva, (2023) la define:

> La IA es una palabra de moda que debéis haber oído mucho en los últimos años. En pocas palabras, este concepto hace refe rencia a una serie de algoritmos y de programas de ordenador que se han di señado para hacer tareas que normalmente requerirían la inteligencia huma na. La IA no es un concepto nuevo, pero los adelantos tecnológicos recientes y las mejoras en potencia computacional lo han hecho más accesible en los últimos años, lo cual ha extendido su uso en diferentes ámbitos. (p.7)

2.2.2 MACHINE LEARNING

Hoy en dia el machine learning es una herramienta muy comun y con el tiempo avanzara mas e inlcuso sera una olbigacion tenerla para la toma de decisiones.

El machine learning ha crecido mucho en los ultimos años y estamos viviendo su auge, Arán (2022) afirmó que:

> El aprendizaje automático o machine learning es una de las ramas de las ciencias de la computación y, en concreto, una de las ramas de la inteligencia artificial. Este

término fue acuñado en el año 1959 por el informático estadounidense Arthur Samuel y hace referencia a las técnicas centradas en el desarrollo de algoritmos que buscan que las máquinas realicen un aprendizaje.

Se considera que una máquina ha realizado un aprendizaje cuando, en base a su experiencia, está haciendo un mejor desempeño de la tarea que le había sido asignada. De este modo, se pueden resolver problemas sin la necesidad de programarlos de forma explícita, ya que la máquina puede desarrollar una lógica propia utilizando los datos que se le proporcionen. (p. 2)

Desde otro enfoque mas moderno Forero y Negre, (2024) la definene como:

> Machine Learning (ML), también conocido como aprendizaje automático o aprendizaje de máquina, es una rama de la inteligencia artificial (IA) que ha tenido un incremento exponencial en los últimos años. La comunidad científica está prestando cada vez más atención a las herramientas educativas enriquecidas con tecnología inteligente, ya que tienen el potencial de revolucionar los procesos de enseñanza aprendizaje.

2.2.3 APRENDIZAJE PROFUNDO

Para Arán (2022) el aprendizaje profundo, una subdisciplina del aprendizaje automático, se caracteriza por el desarrollo de modelos avanzados como las redes neuronales artificiales. Estas estructuras, que contienen múltiples capas de procesamiento, buscan emular el funcionamiento del cerebro humano a través del análisis de grandes volúmenes de información.

Por otro lado, Pérez y Gegúndez, (2021) nos dicen que “El aprendizaje profundo, deep learning en inglés, es un campo del aprendizaje au tomático, machine learning en inglés, que se engloba, a su vez, dentro de la inteli gencia artificial” (p. 191).

2.2.4 TIPOS DE APRENDIZAJE AUTOMÁTICO

2.2.4.1 Aprendizaje Supervisado

Es claro que el aprendizaje supervisado es una técnica dentro del aprendizaje automático que se basa en el uso de un conjunto de datos previamente etiquetado, conocido como conjunto de entrenamiento. En este proceso, el algoritmo recibe pares de datos de entrada y sus respectivas salidas esperadas, lo que le permite aprender la relación entre ambos y, posteriormente, predecir resultados para nuevos datos no vistos Arán (2022).

Prince, (2023) lo define como: “Los modelos de aprendizaje supervisado definen una correspondencia de los datos de entrada a una predicción de salida. En las siguientes secciones, discutimos las entradas, las salidas, el propio modelo y lo que se entiende por “aprender” un modelo” traducido de Prince, (2023) “Supervised learning models define a mapping from input data to an output prediction. In the following sections, we discuss the inputs, the outputs, the model itself, and what is meant by “learning” a model” (p. 1)

2.2.4.2 Aprendizaje No Supervisado

Para Arán (2022) el aprendizaje no supervisado es una rama del aprendizaje automático en la que los algoritmos trabajan únicamente con datos de entrada sin conocer las salidas esperadas. A diferencia del aprendizaje supervisado, no se utilizan pares de entrada-salida, sino que se busca descubrir patrones, relaciones o estructuras ocultas dentro del conjunto de datos mediante su análisis interno.

Desde otra perspectiva: Prince (2023) lo define como:

> Construir un modelo a partir de datos de entrada sin etiquetas de salida correspondientes se denomina aprendizaje no supervisado; la ausencia de etiquetas de salida implica que no puede existir “supervisión”. En lugar de aprender una correspondencia de entrada a salida, el objetivo es describir o comprender la estructura de los datos. Como ocurre con el aprendizaje supervisado, los datos pueden presentar características muy distintas; pueden ser discretos o continuos, de baja o alta dimensionalidad, y de longitud constante o variable.

Traducido de Prince (2023):

> Constructing a model from input data without corresponding output labels is termed unsupervised learning; the absence of output labels means there can be no “supervision.” Rather than learning a mapping from input to output, the goal is to describe or under stand the structure of the data. As was the case for supervised learning, the data may have very different characteristics; it may be discrete or continuous, low-dimensional or high-dimensional, and of constant or variable length. (p. 7)

2.2.5 GRADIENT BOOSTING MACHINE

Estos son modelos novedosos del aprendizaje automatico, los autores

> El gradient-boosting es una técnica de aprendizaje automático que construye un modelo predictivo fuerte a partir de múltiples modelos débiles, generalmente árboles

> de decisión. Funciona iterativamente, optimizando el modelo al corregir los errores de los modelos anteriores mediante la minimización del gradiente de una función de pérdida [38]. Este enfoque permite manejar datos complejos y mejorar la precisión predictiva, haciéndolo especialmente útil en tareas de regresión y clasificación. (Rosales y Rosales, 2025, p. 133)

Otros autores definen GBM como:

> El GBM es un enfoque de aprendizaje supervisado, basado en la combinación secuencial de múltiples árboles de decisión con el objetivo de mejorar la precisión del modelo. A diferencia de métodos como Random Forest, donde los árboles se entrenan de manera independiente, en GBM cada nuevo árbol se construye para corregir los errores cometidos por los árboles anteriores. (Cachaga y Villanueva, 2024, p. 21)

2.2.6 LIGHT GRADIENT BOOSTING MACHINE

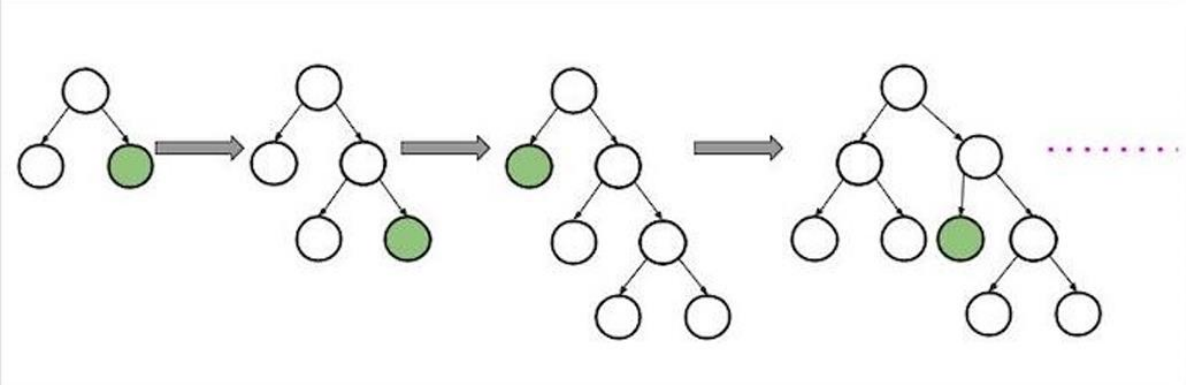
Este algoritmo desarrollado por Microsoft es un algoritmo que de acuerdo con Rosales y Rosales, (2025)

> El algoritmo LightGBM, basado en árboles de decisión, incorpora dos estrategias novedosas: el muestreo unilateral basado en gradientes (GOSS) y la agrupación exclusiva de características (EFB) [40]. Estas estrategias mejoran la velocidad de entrenamiento, la precisión y la eficiencia de LightGBM en comparación con los árboles de decisión de gradient-boosting tradicional (GBDT) [38]. La estrategia GOSS permite eliminar una porción significativa de muestras con gradientes pequeños, mejorando así la eficiencia en el cálculo de la ganancia de información [39]. EFB reduce el número de características agrupando las que son mutuamente excluyentes, optimizando el rendimiento del modelo [40]. (p. 134)

Otros autores nos lo definen como:

> El algoritmo LightGBM es una variante de los algoritmos Boosting optimizada para optimizar y eficiencia computacional requerida al ejecutar el proceso, a diferencia de los otros algoritmos Boosting, LightGBM utiliza un crecimiento de árbol basado en hojas en lugar de nivel, lo que lo hace más veloz y adecuado para grandes volúmenes de datos. (Chilusa, 2025, p. 13)

Figura 2.14 Arquitectura Algoritmo LightGBM



Fuente. Tomado de Yan Gao, (2023).

2.2.7 AMENAZAS PERSISTENTES AVANZADAS (APT)

Es una técnica utilizada para buscar extraer información, Centro Critpológico Nacional, (2020) como se cito en Martínez y Conde (2025) “Las amenazas persistentes avanzadas consisten en una técnica de intrusión a un sistema informático infringiendo las medidas de seguridad, con el propósito de extraer información esencial, con el atacante manteniéndose indetectable durante el mayor tiempo posible” (p. 156).

2.2.8 EXFILTRACIÓN DE DATOS

“La exfiltración de datos, también conocida como extrusión o exportación de datos, es el robo de datos: la transferencia intencionada, no autorizada y encubierta de datos desde un ordenador u otro dispositivo” (IBM, 2026, parr. 1)

2.2.9 DETECCIÓN DE ANOMALÍAS EN EL TRÁFICO DE RED

En este apartado Martín de Diego y Fernández (2020) nos exponen:

> En ocasiones se recomienda comenzar el sistema de aprendizaje con un algoritmo de agrupamiento, incluso cuando tengamos etiquetas y el problema pudiera plantearse como un problema de Aprendizaje Supervisado. De este modo, los algoritmos de agrupamiento permiten obtener una visión de la complejidad de la tarea de clasificación. Consideremos un problema de clasificación de tráfico de red. (p. 145)

2.2.10 SISTEMAS DE DETECCIÓN DE INTRUSOS (IDS)

> Un IDS o sistema de detección de intrusos (por sus siglas en inglés, intrusion detection system) es aquel que monitorea la red y los dispositivos conectados a ella para detectar una posible intrusión y alertar al administrador del sistema. Sin

> embargo, este sistema no está capacitado para imponer medida o acción alguna contra el intruso. (Marcillo y Cordero, 2024, p. 68)

2.2.10.1 Tipos de IDS

De acuerdo con Marcillo y Cordero, (2024) entendemos que:

> Los IDS se pueden clasificar según el sistema que monitorean (NIDS e HIDS) y en función de cómo se implementan (SIDS y SIDA). Por lo tanto, existen cuatro tipos de sistemas de detección de intrusos
>
> Sistema de detección de intrusos en la red (NIDS): Monitorea todo el tráfico de la red en un segmento estratégico para buscar actividades sospechosas y compararla con los ataques conocidos.
>
> Sistema de detección de intrusos en host (HIDS): Monitorea las características de un host y los eventos que ocurren en él en busca de actividades maliciosas o sospechosas.
>
> Sistema de detección de intrusos basados en firmas (SIDS): Analiza los paquetes de datos que entran en la red y los compara con firmas de amenazas conocidas almacenadas en su base de datos.
>
> Sistema de detección de intrusos basado en anomalías (SIDA): Monitoriza el tráfico de red en busca de comportamientos o actividades anómalas, aunque no coincidan con firmas. (p. 68)

2.2.11 SISTEMAS DE PREVENCIÓN DE INTRUSOS (IPS)

Para comprender este concepto nos referimso a Marcilla y Cordero, (2024):

> Un Sistema de Prevención de Intrusiones (IPS) no solo detecta amenazas como lo hace un IDS, sino que también toma medidas automáticas para bloquearlas o mitigarlas en tiempo real. El IPS es una extensión del IDS, con la capacidad añadida de intervenir directamente para proteger la red.

2.2.12 SISTEMAS SIEM

Gracias a Marcilla y Cordero podemos decir que un sistema de gestión de eventos e información de seguridad (*Security Information and Event Management* o SIEM) centraliza y correlaciona de forma automatizada los registros y alertas provenientes de múltiples tecnologías de defensa como cortafuegos y sistemas IDS/IPS (2024).

2.2.13 TRÁFICO DE RED Y REGISTROS

En este apartado la exposición de Marcilla y Cordero, (2024) nos da a entender que:

> El tráfico de red comprende el flujo constante de datos, impulsos eléctricos u ondas electromagnéticas que se transmiten e interconectan entre los nodos de una infraestructura mediante diversos medios de transmisión y protocolos de comunicación. Por su parte, los registros o *logs* representan las evidencias digitales y trazas cronológicas generadas de manera automatizada por los dispositivos de red, servidores y sistemas de seguridad al procesar dicho tráfico, constituyendo la fuente primaria de información para la monitorización, auditoría y análisis de anomalías en entornos corporativos.

2.2.14 TIEMPO MEDIO DE RESPUESTA (MTTD)

De acuerdo con CISCO (2022) podemos afirmar:

> El MTTD es la cantidad de tiempo que suele tar dar un equipo de seguridad en encontrar y confirmar que se ha produ cido una violación a la seguridad. Alcanzar un MTTD bajo es más que solo recibir una alerta y encontrar el sitio del ataque. (p. 15)

2.2.15 FALSOS POSITIVOS

Los falsos positivos son actividades mal identificadas como amenazas, para una explicación mas profunda nos referimos a CISCO (2022):

> En el contexto de la seguridad, los falsos positivos son actividades benignas que se identifican erróneamente como amenazas a la seguri dad. Tal vez un administrador de la base de datos se marcha a la hora de almuerzo después de comenzar un gran trabajo de exportación. Mien tras tanto, un empleado de seguridad de la red cancela su almuerzo porque ve un gran volumen de tráfico en la red que no esperaba.
>
> Para empeorar las cosas, se suponía que su almuerzo iba a ser un delicioso sándwich de pollo katsu. ¡Qué desperdicio terrible! Las violaciones de seguridad que son falsos positivos no solo causan interrupciones innecesarias y pérdida de tiempo, sino que también dejan pasar inadvertidamente violaciones de seguridad reales. La fatiga de las alertas se asemeja al “Pastorcito mentiroso”. Digamos que, en promedio, un equipo de seguridad de aplicativos recibe diez alertas de seguridad todos los días, pero solo dos de ellas son amenazas legítimas. Si esto pasa durante unos pocos días no es un problema, pero si hay semanas de alertas falsas, el equipo no prestará

> mucha atención a las alertas. Después de todo, lo más probable es que no sea una amenaza real. (p. 16)

2.2.16 PUNTAJE F1-SCORE

De acuerdo con Arias (2024):

> El F1-score, también llamado F-score o medida F, es un estimador de la capacidad de clasificación de una prueba que se usa con frecuencia en la ciencia de datos y en los algoritmos de inteligencia artificial y que puede ser de utilidad para la valoración de las pruebas diagnósticas. Es la media armónica de sensibilidad y valor predictivo positivo, por lo que pondera el valor de ambos en un solo estimador. (p. 1)

2.3 MARCO INSTITUCIONAL

El marco institucional provee el contexto fundacional empírico, estructural y tecnológico que define a la organización objeto de estudio. Es a través de la comprensión detallada de su andamiaje jerárquico, su filosofía operativa y las limitaciones de su infraestructura actual que se logra justificar rigurosamente la necesidad de aplicar arquitecturas de software modernas, lenguajes con control de memoria determinista y modelos predictivos de inteligencia artificial en la mitigación de los riesgos de ciberseguridad.

2.3.1 ANTECEDENTES DE LA INSTITUCIÓN

Cualquier esfuerzo de modernización tecnológica e implementación de sistemas heurísticos predictivos debe, imperiosamente, acoplarse con la evolución histórica y el entorno operativo particular de la entidad, reconociendo que los desafíos de escalabilidad actuales son producto de un crecimiento orgánico de red y de las exigencias del mercado digital.

2.3.1.1 Reseña Histórica De La Empresa/Institución

La Empresa/Institución objeto del presente marco se ha consolidado en las últimas décadas como un actor fundamental en la provisión de servicios digitales y la orquestación de comunicaciones corporativas. Nacida inicialmente como un proveedor local de infraestructura estática para redes de área metropolitana, la institución ha experimentado un profundo proceso de evolución y transformación digital constante. Su migración hacia servicios gestionados en la nube y la adopción progresiva de soluciones de interconexión han multiplicado su capacidad operativa, pero al mismo tiempo, han heredado sistemas transaccionales monolíticos forjados en etapas tempranas que hoy en día enfrentan desafíos mayúsculos para mantenerse al ritmo de las transacciones masivas.

De acuerdo con Bhattacharyya, (2024):

El diseño de la estructura organizacional contemporánea exige una adaptabilidad sin precedentes, donde la división de áreas debe facilitar no solo el flujo de información gerencial, sino también la rápida asimilación de nuevas tecnologías y la respuesta inmediata ante disrupciones del mercado global y las crecientes presiones de seguridad en el perímetro extendido. (p. 45).

2.3.1.2 Filosofía Institucional

La adopción de soluciones de software de vanguardia se rige inexorablemente por la filosofía subyacente que moldea las operaciones tácticas y la dirección estratégica general de la entidad.

2.3.1.3 Misión

La misión central de la institución se focaliza en dotar al ecosistema corporativo e individual de una infraestructura de telecomunicaciones ininterrumpida, convergente y extremadamente resiliente, asegurando permanentemente la conectividad de alta velocidad y protegiendo el flujo irrestricto, pero estrictamente confidencial de la información a través de la integración incesante de tecnologías de última generación.

2.3.1.4 Visión

La visión estratégica de la entidad persigue el posicionamiento como el referente internacional indiscutible en la provisión de arquitecturas de red puramente seguras y operaciones de tecnología predictivas, impulsando incansablemente una digitalización sin fisuras donde los ciberataques sean neutralizados proactivamente en tiempo real mediante el uso de inteligencia analítica avanzada, sin comprometer jamás la agilidad del negocio o la privacidad de sus abonados.

2.3.1.5 Valores Corporativos Y Objetivos Estratégicos

Los valores corporativos fundamentales —integridad absoluta, innovación tecnológica constante, excelencia operativa y responsabilidad en la custodia de datos— dictaminan el comportamiento de todos los engranajes de la corporación. David, (2023) "Cada capítulo finaliza destacando conceptos y herramientas importantes que utilizan los estrategas que realmente construyen sistemas sostenibles" (p. 15). Estos valores se materializan operativamente en objetivos estratégicos rígidos: la minimización sistemática de la superficie de ataque, el cumplimiento irrestricto de las normas globales de privacidad de la información, y la optimización continua de los tiempos de respuesta del equipo de operaciones y tecnología.

2.3.2 ESTRUCTURA ORGANIZACIONAL

La arquitectura organizativa dictamina cómo se delega la toma de decisiones tecnológicas, delineando cómo los componentes de auditoría, las operaciones puras y el desarrollo de ingeniería interactúan orgánicamente en el despliegue del sistema.

2.3.2.1 Organigrama General De La Institución

El diseño estructural de la corporación exhibe una topología matricial moderna y sumamente aplanada, alejándose de los modelos rígidos en silos. Encabezada por una Junta Directiva y una Gerencia General Ejecutiva (CEO), el organigrama se ramifica en direcciones estratégicas interconectadas: la Dirección de Operaciones (COO), la Dirección Financiera (CFO), la Dirección Comercial, y de suma relevancia para la continuidad del negocio, la Dirección General de Tecnología e Información (CIO/CISO), la cual sostiene estructuralmente y gestiona holísticamente la columna vertebral digital de toda la compañía.

2.3.2.2 Descripción De Las Gerencias O Áreas Principales

Dentro de la Dirección de Tecnología, las áreas subyacentes se segmentan metodológicamente según su responsabilidad transaccional y su rol en el Ciclo de Vida del Sistema:

- Gerencia de Desarrollo e Ingeniería de Software: Responsable de la creación de aplicaciones internas, el mantenimiento de APIs y la implementación de despliegues mediante integración continua.
- Gerencia de Infraestructura y Nube: Encargada de mantener los nodos físicos perimetrales, orquestar contenedores (Kubernetes) y velar por el estado del hardware y los enlaces de telecomunicaciones puros.
- Gerencia de Ciberseguridad y Riesgos: Unidad fundamental encargada de diseñar el gobierno de la protección de datos corporativos, administrar las identidades IAM, modelar amenazas y asegurar la auditoría criptográfica, a la cual se supedita operativamente el Centro de Operaciones de Seguridad (SOC).

2.3.3 DESCRIPCIÓN DEL ÁREA DE ESTUDIO

El enfoque de la presente problemática se ancla específicamente en el ecosistema logístico y operacional dedicado a la prevención técnica activa y a la respuesta frente a incidentes cibernéticos que involucran el riesgo extremo de fuga de la información confidencial de la institución.

2.3.3.1 Estructura Del Departamento De Tecnologías De La Información (TI)

El Departamento de Tecnologías de la Información, y específicamente su rama de Seguridad Operativa, atraviesa actualmente un rediseño monumental impulsado por la complejidad del nuevo tráfico cifrado. "El sesenta y tres por ciento de los líderes globales planean reinventar su función de TI en los próximos tres años para mantenerse por delante de las incesantes interrupciones tecnológicas" (Accenture, 2025, p. 2). Esta unidad especializada se organiza internamente combinando una célula táctica de ingeniería de seguridad (arquitectos de red que configuran cortafuegos y políticas de control) y un equipo operacional que monitorea activamente el pulso de las comunicaciones, actuando como la primera línea de defensa frente a exfiltraciones sofisticadas.

2.3.3.2 Funciones Específicas Del Equipo De Monitoreo O SOC (Centro De Operaciones De Seguridad)

El SOC de la institución actúa funcionalmente como el sistema nervioso central e incesante del ecosistema digital, y es exactamente allí donde el problema de exfiltración lateral no mitigado tiene su impacto destructivo. Evani, (2025) "El SOC moderno ahora debe anticipar amenazas, adaptarse a pilas tecnológicas en constante cambio y absorber el impacto de una brecha con una interrupción mínima para el negocio" (p. 1).

Las responsabilidades críticas y operacionales exigidas al equipo de analistas y gestores del SOC abarcan:

Ingesta y Triage: Analizar diariamente innumerables colas de alertas generadas de manera estática y correlacionada por los sistemas perimetrales.

Identificación y Caza de Amenazas (Threat Hunting): Rastrear heurísticamente comportamientos anómalos, buscar el tráfico lateral oculto de tipo APT y perseguir proactivamente a actores maliciosos que evadan los controles booleanos iniciales.

Respuesta Inmediata y Contención: Actuar como comandantes del incidente técnico y cortar quirúrgicamente las sesiones de red sospechosas o subprocesos comprometidos sin generar caídas sistémicas en servicios legítimos.

Una descripción de exactamente qué necesita ser conocido cuando un endpoint es puesto en una red, con roles, responsabilidades, y con requerimientos de actualización, es parte de un perfil Zero Trust maduro de la organización. El uso de

un proceso de integración consistente asegurará que se pueda practicar una defensa optimizada y eficiente en el ecosistema del SOC. (Muniz, 2021, p. 18).

2.3.4 INFRAESTRUCTURA TECNOLÓGICA ACTUAL

La raíz técnica irrefutable de la incapacidad operativa del SOC institucional para frenar el ciclo complejo de exfiltración de datos no reside en la falta de capacidad humana, sino primordialmente en la obsolescencia subyacente, la ineficiencia arquitectónica y la saturación matemática de su actual infraestructura analítica y de software perimetral.

2.3.5 ARQUITECTURA DE RED Y SISTEMAS DE INFORMACIÓN EXISTENTES

Actualmente, la institución posee una arquitectura de red fragmentada y transitoria. Los sistemas de información operativos y de backend han sido históricamente programados y desplegados utilizando lenguajes de scripting interpretados (como Python) y monolitos basados en C++, lo cual impone barreras masivas de rendimiento, sobrecarga de paralelismo y un persistente historial de vulnerabilidades de memoria (fugas de búfer y data races) que las APT explotan para evadir controles. Adicionalmente, el enrutamiento perimetral sigue dependiendo de esquemas de inspección tradicionales que no logran escalar de manera asíncrona ante el abrumador flujo actual de micro-transacciones en la nube corporativa, forzando a los componentes del sistema a encolar y a retrasar inexorablemente las validaciones críticas.

"Rust proporciona ventajas únicas, su modelo de gestión de memoria permite el procesamiento de datos a alta velocidad sin la sobrecarga común en lenguajes interpretados" (Van Der Post, 2024, p. 12). La adopción formal de un ecosistema en Rust para renovar las sondas de tráfico y el uso del framework web Axum para el enrutamiento de transacciones internas, resulta por tanto ingenieril e imperativamente necesario, al proporcionar garantías de memoria estrictas mediante el ownership, concurrencia asíncrona limpia a través de Tokio, e infraestructuras API escalables que no consumen exponencialmente los recursos del servidor físico de recolección.

2.3.5.1 Manejo Actual De Logs, Bases De Datos Y Volumen De Información Procesada

El cuello de botella fundamental y catastrófico reside en el procesamiento y almacenamiento de los inmensos océanos de telemetría de red. Gupta y Mamta, (2024)

La cantidad de datos generados por la multitud de dispositivos interconectados aumenta exponencialmente, lo que hace que el almacenamiento y procesamiento de estos datos sea

un verdadero desafío. La gestión y analítica de Big Data han ganado un impulso decisivo en casi todas las industrias modernas de la actualidad. (p. 5).

El sistema SIEM legado de la corporación maneja el ingente y asíncrono volumen de registros temporales o logs (que frecuentemente exceden los terabytes diarios de tramas IP, metadatos DNS y registros de actividad del servidor) apoyándose en bases de datos relacionales lentas o estructuras indexadas que experimentan retardos inmanejables al momento de aplicar heurística. El modelo algorítmico reactivo actual es inviable, colapsando matemáticamente frente a la "explosión de complejidad" y el diluvio infinito de Falsos Positivos documentados en redes de este calibre.

Para mitigar esta saturación y dotar al SOC del poder analítico en tiempo casi real que requiere, se exige migrar forzosamente a una infraestructura de manipulación columnar hiper-rápida. "Polars está implementado nativamente en Rust con un motor de consultas analíticas y utiliza el formato columnar de Apache Arrow como su modelo de memoria subyacente" (Pedreira et al., 2023, p. 2680). La extrema eficiencia de Polars para leer, agrupar y vectorizar flujos asíncronos en RAM habilita la preparación casi instantánea de la Ingeniería de Características. Por último, la ingesta masiva de esta estructura tabular compacta (pre-procesada por Polars) resulta el alimento ideal para la implementación predictiva final de clasificadores como el ensamble LightGBM, el cual, gracias a sus optimizaciones estructurales GOSS y EFB, será capaz por fin de inferir asíncronamente y bloquear la exfiltración silenciosa dentro de los márgenes estrechos de milisegundos exigidos en un esquema hiper-conectado.

2.4 MARCO NORMATIVO

El marco normativo constituye el compendio ineludible de leyes, decretos, reglamentaciones técnicas y estándares internacionales que otorgan validez jurídica, delimitan la ética del tratamiento de la información y regulan las operaciones tecnológicas objeto de la investigación. La adopción de sistemas predictivos de IA y el desarrollo de arquitecturas robustas para detener la exfiltración deben forzosamente orbitar y dar cumplimiento a los parámetros exigidos por los estados y los reguladores tanto locales como a nivel global.

2.4.1 NORMATIVA INTERNA (TIGO - TELECEL S.A.)

Para garantizar el cumplimiento de sus objetivos institucionales, la operadora ha consolidado su propia batería de normas de cumplimiento interno y protección.

- **Política de Clasificación y Manejo de Datos:** Establece categorías estrictas para la información (pública, interna, confidencial y restringida), garantizando que las bases de datos transaccionales, como las evaluadas en este estudio, no se encuentren expuestas por roles de IAM erróneos o en configuraciones no autorizadas en nubes públicas.
- **Política de Gestión y Respuesta a Incidentes de Ciberseguridad:** Dicta operativamente los procedimientos del SOC ante brechas, exigiendo la contención asíncrona de ataques, incluyendo vulnerabilidades de tipo "zero-day" y extracciones anómalas descubiertas en la red de forma dinámica.
- **Política de Privacidad y Protección de Datos de Clientes:** Regula el resguardo absoluto de la Privacidad de los usuarios finales (PII). Millicom, (2024)

Sujeto a la ley en el mercado donde usted resida, autoridades locales, tribunales, otros organismos de resolución de disputas y agencias encargadas de hacer cumplir la ley pueden tener permitido y/o requerido por ley solicitar y usar sus datos personales. (p. 2)

- **Código de Ética y Conducta Corporativa:** "Las políticas estipulan que todos los proveedores están obligados a firmar el Código de Conducta para Proveedores de la corporación durante su integración" (Millicom, 2024, p. 2). Este documento es de aceptación anual obligatoria para evitar el riesgo originado por el factor humano.

2.4.2 NORMATIVA NACIONAL (BOLIVIA)

El anclaje de un proyecto de seguridad debe atenerse a las regulaciones de la nación donde se despliegue la infraestructura de la red, respetando los derechos constitucionales.

2.4.2.1 Decreto Supremo N° 1793 - Reglamento de la Ley N° 164

Emitido el 13 de noviembre de 2013. En concordancia con la Ley 164, este reglamento aborda en su Artículo 4 (Obligaciones de los Operadores) y Artículo 5 (Parámetros de Calidad) los mecanismos técnicos detallados para mantener estándares óptimos en la red. Estas normativas obligan a la operadora a garantizar que la infraestructura no presente anomalías ni degradaciones originadas por ciberataques (como las generadas durante la extracción masiva de información), justificando así la necesidad de un sistema de detección y monitoreo en tiempo real.

2.4.2.2 Resoluciones Regulatorias de la Autoridad de Regulación y Fiscalización de Telecomunicaciones y Transportes (ATT)

Directrices de orden vinculante emitidas hacia los operadores públicos para auditar, supervisar y penalizar faltas relacionadas con la seguridad y confidencialidad de la infraestructura tecnológica nacional.

2.4.2.3 Código Penal Boliviano

"El que con la intención de obtener un beneficio indebido para sí o un tercero, manipule un procesamiento o transferencia de datos informáticos" (Estado Plurinacional de Bolivia, 2024, p. 31). Los artículos 363 Bis (Manipulación informática) y 363 Ter (Alteración, acceso y uso indebido de datos informáticos) tipifican explícitamente y sancionan los ataques cibernéticos a infraestructuras en territorio nacional.

2.5 ESTADO DEL ARTE

El estado del arte constituye una investigación documental de carácter crítico que expone las fronteras actuales del conocimiento técnico y metodológico. Este escrutinio riguroso, centrado en estudios, tesis, monografías y artículos científicos publicados de forma estricta a partir del año 2020 en adelante, persigue identificar vacíos investigativos (research gaps), corroborar la validez de la aplicación de la inteligencia artificial en topologías de red, y fundamentalmente, comparar el presente proyecto de grado frente a iniciativas académicas y corporativas nacionales e internacionales análogas, demostrando las diferencias arquitectónicas y la innovación tecnológica superadora que supone el uso conjunto de Rust y el modelo LightGBM.

2.5.1 REVISIÓN Y COMPARACIÓN DE PROYECTOS NACIONALES

Las investigaciones desarrolladas dentro de la coyuntura académica de la región reflejan la adopción creciente de marcos de ciberseguridad y modelos predictivos para afrontar vulnerabilidades estructurales en ecosistemas empresariales.

2.5.1.1 Primer Proyecto

Aplicación De La Metodología Zero Trust Para Mejorar La Seguridad En La Infraestructura De Red

Autor: Murga, R.

Año: 2022

Institución: Universidad Mayor de San Andrés (UMSA), La Paz, Bolivia.

Resumen: La investigación expone una implementación cuasi-experimental orientada a subsanar debilidades de autenticación de usuarios y filtraciones de datos desde módulos empresariales mediante la adopción de principios de confianza cero (Zero Trust).

Similitudes: Ambos proyectos comparten la misma fundamentación técnica basada en mitigar los vectores de ataque laterales y el movimiento no autorizado (enrutamiento de datos). Además, ambos proyectos asimilan operativamente modelos estandarizados para reforzar el diseño organizacional de seguridad frente a APTs.

Diferencias: El estudio de Murga (2022) posee un perfil estrictamente arquitectónico y procedimental, centrándose en aplicar políticas perimetrales de restricción de identidad (Identity Access Management), sin involucrar ninguna herramienta de inteligencia artificial ni análisis automatizado del tráfico de red subyacente para detectar anomalías estocásticas.

2.5.1.2 Segundo Proyecto

Aplicación De Técnicas De Machine Learning A La Ciberseguridad: Aprendizaje Supervisado Para La Detección De Amenazas Web

Autor: Dueñas Quesada, A.

Año: 2020

Institución: Universitat Oberta de Catalunya (UOC), Barcelona, España (relevante al contexto regional).

Resumen: Desarrolla un modelo analítico enfocado en la clasificación de peticiones de tráfico de red (HTTP) para segmentar anomalías utilizando algoritmos de aprendizaje supervisado basados en árboles de decisión.

Similitudes: Existe una correlación metodológica idéntica respecto al uso primario de algoritmos de Machine Learning de aprendizaje supervisado basados en árboles de decisión para procesar metadatos cibernéticos y clasificar el comportamiento del tráfico de la red.

Diferencias: Dueñas (2020) se apoyó en algoritmos genéricos implementados a través de bibliotecas tradicionales (Scikit-learn en lenguaje Python), operando únicamente sobre conjuntos de datos estáticos y reducidos, lo cual arrastra deficiencias críticas de velocidad computacional frente a volúmenes masivos de datos (Big Data).

2.5.2 REVISIÓN Y COMPARACIÓN DE PROYECTOS INTERNACIONALES

La literatura internacional en foros indexados y estudios de posgrado consolida la pertinencia de la evaluación algorítmica de vanguardia para mitigar las intrusiones de red complejas.

2.5.2.1 Primer Proyecto

Comparativa De Algoritmos De Aprendizaje Automático Para La Detección De Tipos Específicos De Malware En Entornos Adversos

Autor: Guale Rosales, J. Y.

Año: 2025

Institución: Universidad Estatal Península de Santa Elena (UPSE), Ecuador.

Resumen: Desarrolla una evaluación rigurosa donde somete a escrutinio el rendimiento métrico de diversos algoritmos clasificatorios contra flujos de software malicioso y comportamientos adversos en terminales.

Similitudes: La investigación converge en la misión estratégica de fortalecer los sistemas preventivos informáticos evaluando métricas estrictas de aprendizaje automático y abogando por la defensa proactiva contra el accionar de amenazas en las redes actuales.

Diferencias: La tesis mencionada se orienta puramente hacia el análisis de la detección tipológica de malware estático o ejecutable en terminales, sin enfocar el núcleo de su entrenamiento analítico en la evasión perimetral, la telemetría dinámica asíncrona ni el proceso encubierto específico de fuga progresiva de información confidencial (Data Exfiltration).

2.5.2.2 Segundo Proyecto

Algoritmos De Machine Learning E Inteligencia Artificial En La Detección De Patrones De Ciberataques

Autores: Obregón-Martínez, M., et al.

Año: 2025

Institución: Revista Multidisciplinaria de Perspectivas Investigativas (Estudio multicéntrico internacional).

Resumen: Examinan el rol decisivo de los meta-ensambles avanzados y algoritmos de gradiente optimizado (como LightGBM) en la detección de patrones de ciberataques distribuidos en plataformas corporativas y de nube.

Similitudes: El reconocimiento universal de LightGBM como la solución de frontera para procesar matrices densas e identificar patrones estocásticos de ciberataques ocultos en inmensos registros es un denominador común absoluto y base teórica principal de ambos estudios.

Diferencias: Estos artículos internacionales se limitan fundamentalmente al análisis algorítmico, operando conceptualmente en entornos controlados de laboratorio para la validación de métricas (F1-Score), sin diseñar la arquitectura de un sistema web empresarial completo ni resolver los desafíos del procesamiento de memoria de bajo nivel.

BIBLIOGRAFÍA

AGETIC - CSIRT Bolivia. (2025). *Informe de Gestión de Incidentes y Vulnerabilidades Informáticas: Tercer Trimestre 2025.* La Paz: Agencia de Gobierno Electrónico y Tecnologías de Información y Comunicación.

Aniche, M. (2022). *Effective Software Testing: A Developer's Guide.* Manning Publications.

Arán Godés, 2. (2022). *Metodos de aprendizaje automático y aplicaciones.* Universidad de Zaragoza.

Aurelio, M. (2024). *UM - A Simple Guide for Beginners.* Amazon KDP.

Aurelio, M. (s.f.). *UML - A Simple Guide for Beginers.*

Australian Signals Directorate. (2026). *Information Security Manual.* Australian Cyber Security Centre.

Autoridad de Regulación y Fiscalización de Telecomunicaciones y Transportes (ATT). (2025). *Estado de Situación de las Telecomunicaciones en Bolivia: Gestión 2024.* ATT.

Autoridad de Supervisión del Sistema Financiero. (2025). *Ciberdelincuencia.* ASFI.

Bernal Ontiveros, J. M., Palacios Reyes, M., Zorrilla Briones, F., Rosales Morales, N. R., & Cervantes Cardenas, S. A. (2025). *Ciberseguridad: Métodos de Defensa Ante Ataques de Infiltraciones.* Revista Iberoamericana para la investigación y el Desarrollo Educativo.

Bertolini, P., Cruz, M., & Bravo, J. (2023). *Redesde Nueva Generación el futuro de la conectividad y la transformación digital.* Digital Trends.

Briano, C. A. (2023). *Compilación de apuntes sobre conceptos fundamentales de la Ingeniería de Software: con una visión orientada a proyectos vinculados con las Ciencias Económicas.* César Ariel Briano.

Briva Iglesias, V. (2023). *Inteligencia Artificial (IA).* Universitat Oberta de Catalunya.

Cachaga Herrera, P., & Villanueva Osorio, D. M. (2024). Nowcast del PIB mediante algoritmos de machine learning: Una evaluación en tiempo real *. *Revista de Análisis, 41*, 9-64.

Celi Párraga, R. J., Boné Andrade, M. F., Mora Olivero, A. P., & Sarmiento Saavedra, J. C. (2023). *Ingeniería del Software I: Requerimientos y Modelado del Software.* Grupo AEA.

Centro Critpológico Nacional (CCN-CERT). (2021). *Principios y recomendaciones básicas en ciberseguridad.* Gobierno de España, Ministerio de Defensa.

Check Point Software Technologies Ltd. (2026). *Cyber Security Report 2026* (14th ed.). (L. Finkelstein, Ed.) Check Point Research.

Chilusa Cabezas, J. I. (2025). *Evaluación de algoritmos de diagnóstico para mantenimiento basado en la condición en motores trifásicos W22: XGBoost, LightGBM y CatBoost.* Escuela Superior Politécnica de Chimborazo.

Cubero, H. (2020). *PROCESOS DE INGENIERÍA DE SOFTWARE.*

Debrauwer, L., & Van Der Heyde, F. (2020). *UML 2.5: Iniciación, ejemplos y ejercicios corregidos* (5th ed.). Ediciones ENI.

ESET. (2024). *ESET Security Report Latinoamérica 2024.* ESET Latinoamérica. ESET.

Forero Corba, W., & Negre Bennasar, F. (2024). *Técnicas y aplicaciones del Machine Learning e Inteligencia Artificial en educación: una revisión sistemática.* RIED-Revista Iberoamericana de Educación a Distancia. https://doi.org/https://doi.org/10.5944/ried.27.1.37491

Hernandéz, M., & Baquero, L. (2020). *Fundamentos de Programación Web.* Editorial Universidad ECCI.

IBM Security. (2025). *Cost of a Data Breach Report 2025.* IBM Corporation. https://doi.org/https://www.ibm.com/reports/data-breach

International Organization for Standardization (ISO). (Marzo de 2022). *ISO/IEC 27001:2022*. www.iso.org: https://www.iso.org/es/norma/27001

International Telecommunication Union. (2025). *Security in Telecommunications and Information Technology (8th edition).* (K. H. Oh, Ed.) Geneva, Suiza: ITU-T.

Leptos Team. (8 de May de 2026). *Leptos: A full-stack, isomorphic Rust web framework*. Docs.rs: https://docs.rs/leptos/latest/leptos/

Millicom International Cellular S.A. (2024). *Annual Report 2024 (Form 20-F).* U.S. Securities and Exchange Commission.

Millicom International Cellular S.A. (2025). *Annual Report 2024: Building the Digital Highways.* Millicom.

Minnick, C. (2023). *JavaScript All-in-One For Dummies.* John Wiley & Sons.

Muñoz Guerrero, L. E. (2024). *Rust para inteligencia artificial: Una introducción al machine learning.* Corporación Centro Internacional de Marketing Territorial para la .

Ñaupas Paitán, H., Mejía Mejía, E., Trujillo Román, I. R., Romero Delgado, H. E., Medina Bárcena, W., & Novoa Ramírez, E. (2023). *Metodología de la Investigación Total Cuantitativa - Cualitativa y Redacción de Tésis* (6th ed.). Ediciones de la U.

Nokia. (2024). *Threat Intelligence Report 2024: What's next for telecom.* Nokia OYJ. Nokia.

Ortuño Perez, M. (2025). *Programación Web: HTML, CSS, JavaScript.* Universidad Rey Juan Carlos.

Pérez Borrero, I., & Gegúndez Arias, M. E. (2021). *Deep Learning.* Servicio Publicaciones Universidad de Huelva.

Pérez Hernández, J. Á., & Sánchez Trujillo, M. G. (2021). *International Conference on Project Management 2021.* ean universidad.

Prince, S. J. (2023). *Understanding Deep Learning.* The MIT Press.

Raschka, S., Liu Yuxi, & Mirjalili, V. (2022). *Machine Learning with PyTorch and Scikit-Learn: Develop machine learning and deep learning models with Python.* Expert Insight.

Reyez Cruz, M., & Reyes Cruz, E. (2024). *Investigar con Perspectiva Intelectual.* Comunicación Cientifica. https://doi.org/10.52501/cc.217

Rivero, G. F., & López Espada, J. L. (2025). *Ciberseguridad Inteligente: Prevención y Respuesta Autónoma.* Centro Demostrador TIC (CDTIC), Junta de Extremadura.

Rodríguez-Toro, O. (2024). *El método general de Investigación Cientifica y Dieciseis Metodos de Investigación.* Ed. Mirdav Natsar Desarrollo literario.

Rosales Malpartida, J. Y., & Rosales Cutipa, V. A. (2025). Comparación de los modelos LightGBM y XGBoost para la predicción a la resistencia a la comprensión del concreto. *Revista Cientifica TecnoHumanismo, 5*, 129-146.

Sarker, I. (2021). *Machine Learning: Algorithms, Real-World Applications and Research Directions.* SN Comput Sci.

SecurityScorecard. (2025). *2025 Global Third-Party Breach Report: From Ratings to Resilience.* SecurityScorecard.

Sletten, B. (2024). *WebAssembly: La Guía Definitiva.* O'Reilly Media, Inc.

Tokio Team. (8 de May de 2026). *Axum: Ergonomic and modular web framework (Versión 0.7.5)*. Docs.rs: https://docs.rs/axum/latest/axum/

Wójcik, K., Kaputsa, J., Skalka, J., Benkova, L., Turčínek, J., Polak, I., . . . Francisti, J. (2021). *HTML Fundamentals.* FITPED.

Yan Gao. (2023). *Towards Data-Driving Multi-View Evaluation Framework.* IEEE (Institute of Electrical and Electronics Engineers).

APÉNDICES

APÉNDICE 1: TRANSCRIPCIÓN DE ENTREVISTA DE LEVANTAMIENTO DE INFORMACIÓN (VÍA WHATSAPP)

Objetivo: Recopilar información técnica sobre las limitaciones actuales en la detección de exfiltración de datos en Tigo Business Bolivia.

Modalidad: Conversación vía WhatsApp**.**

El entrevistado acepta participar voluntariamente en esta entrevista, autorizando el uso exclusivo de los datos proporcionados para fines académicos e investigativos del presente Proyecto de Grado, manteniendo la confidencialidad de datos sensibles de la empresa.

Datos del Entrevistado:

Cargo: Ingeniero Especialista en Ciberseguridad.

Fecha de aplicación: 15 de marzo de 2026.

[15/03/2026, 10:15] Jorge Medrano (JM): Hola Ing., ¿cómo está? Quería hacerle unas consultas rápidas por acá para mi proyecto de grado sobre cómo estamos con la detección de fuga de datos en el SOC. ¿Tiene unos minutos?

[15/03/2026, 10:22] Ingeniero SOC (IS): Hola Jorge. Claro, dale. Te respondo por acá entre reuniones.

[15/03/2026, 10:23] Jorge Medrano (JM): ¡Gracias! Primero: ¿Cuál diría que es el mayor problema que tenemos hoy en el SOC para detectar si nos están robando información?

[15/03/2026, 10:26] Ingeniero SOC (IS): El problema principal es que los sistemas que usamos ya están desactualizados. Funcionan con "firmas" (reglas fijas). Si el ataque es nuevo o cambia un poco, el sistema simplemente no lo reconoce.

[15/03/2026, 10:28] Jorge Medrano (JM): Entiendo. ¿Y eso cómo les afecta en el trabajo del día a día revisando las alertas?

[15/03/2026, 10:31] Ingeniero SOC (IS): Nos satura de falsos positivos. El sistema salta por cualquier cosa sospechosa pero que termina siendo tráfico normal. Perdemos muchísimo tiempo revisando a mano alertas que no son nada.

[15/03/2026, 10:33] Jorge Medrano (JM): Mucho ruido entonces. ¿Y qué pasa con el tiempo de respuesta? ¿Tardamos mucho en darnos cuenta si hay una fuga real?

[15/03/2026, 10:36] Ingeniero SOC (IS): Sí, tardamos demasiado. A veces los datos ya salieron de la empresa para cuando nos llega la alerta o nos damos cuenta. Básicamente, estamos reaccionando al problema cuando ya pasó, en vez de prevenirlo.

[15/03/2026, 10:38] Jorge Medrano (JM): Me imagino que los atacantes también usan trucos más difíciles de ver ahora.

[15/03/2026, 10:41] Ingeniero SOC (IS): Exacto. Hacen ataques muy lentos y silenciosos para no levantar sospechas, o esconden los datos robados en conexiones que parecen normales. Nuestros sistemas actuales no están hechos para ver eso. Además, los servidores a veces se saturan de tanto tráfico que tienen que analizar.

[15/03/2026, 10:43] Jorge Medrano (JM): Última consulta Ing: Si metemos Inteligencia Artificial, como el algoritmo LightGBM para que aprenda el comportamiento del tráfico, ¿cree que nos ayude a solucionar esto?

[15/03/2026, 10:46] Ingeniero SOC (IS): Totalmente. Si una IA aprende cómo es el tráfico normal, puede detectar comportamientos raros al instante sin depender de reglas viejas. Nos filtraría la basura, veríamos solo las alertas reales y podríamos bloquear la fuga a tiempo. Sería un cambio enorme para el equipo.

[15/03/2026, 10:48] Jorge Medrano (JM): ¡Queda clarísimo! Mil gracias por su tiempo Ing., me sirve muchísimo para justificar el desarrollo.

[15/03/2026, 10:50] Ingeniero SOC (IS): De nada Jorge. Éxitos con el proyecto, nos avisas cómo avanza.

CONCLUSIONES DERIVADAS DE LA ENTREVISTA Y PRECISIONES METODOLÓGICAS

A partir del diagnóstico empírico proporcionado por el especialista del SOC, se valida la necesidad de transicionar de un enfoque reactivo basado en firmas hacia un modelo inteligente. Sin embargo, para alinear las expectativas operativas expresadas en la entrevista con el marco metodológico del proyecto, se establecen las siguientes precisiones técnicas:

- Tipo de Aprendizaje y Mecanismo de Etiquetado: Aunque a nivel coloquial se mencionó que la IA "aprende cómo es el tráfico normal", el sistema propuesto no operará como un modelo genérico de detección de anomalías no supervisado. Se implementará LightGBM estrictamente como un algoritmo de aprendizaje supervisado. Esto requiere que, durante la fase de entrenamiento y evaluación, el

modelo procese conjuntos de datos (datasets) donde cada registro haya sido previamente etiquetado de forma explícita, identificando a qué clase pertenece: tráfico legítimo o tráfico asociado a exfiltración.

- Límites de Acción (Mitigación): Respecto a la expectativa operativa de "bloquear la fuga", es imperativo aclarar que el alcance técnico del sistema está delimitado exclusivamente a la optimización de los tiempos de detección y notificación (generación de alertas de alta fidelidad). El sistema no ejecutará bloqueos automáticos (mitigación activa) sobre la infraestructura de red de Tigo Business, evitando así el riesgo de interrumpir servicios corporativos críticos por potenciales falsos positivos.

APENDICE 2: ESTIMACIÓN DE EVENTOS MENSUALES TIGO BUSINESS BOLIVIA

En el presente apéndice se detalla la metodología utilizada para estimar el volumen de eventos de red procesados por Tigo Bolivia. El cálculo se basa en la proporción de clientes de Bolivia respecto al total de Millicom (≈11%), de los 46 millones obtenidos de Millicom International Cellular S.A., (2024, p. 47)

Basado en los reportes de tráfico de redes móviles de la Autoridad de Regulación (ATT, 2025) y los estándares de generación de logs en telecomunicaciones (Nokia, 2024), se estima un promedio de 100 eventos transaccionales diarios por cliente, considerando que cada registro de tráfico (log) constituye un evento independiente, sin importar la cantidad de paquetes asociados.

Clientes estimados en Bolivia: 5 millones (≈11% de 46 millones globales).

Eventos diarios por cliente: 100.

Eventos diarios totales Bolivia:

$$5{,}000{,}000 \times 100 = 500{,}000{,}000$$

Eventos mensuales Bolivia:

$$500{,}000{,}000 \times 30 = 15{,}000{,}000{,}000$$

Este resultado permite dimensionar la capacidad de procesamiento requerida por la infraestructura de Tigo Bolivia y constituye un insumo metodológico para el análisis de escalabilidad y seguridad.

APÉNDICE 3: RESULTADOS DEL CUESTIONARIO TÉCNICO ESTRUCTURADO

Objetivo: Recopilar evidencia cuantitativa y técnica sobre las limitaciones operativas actuales en la detección de exfiltración de datos en la infraestructura de Tigo Business Bolivia, validando la necesidad de implementar un modelo predictivo.

Modalidad: Cuestionario técnico estructurado en línea (vía Google Forms).

Consentimiento Informado: El entrevistado aceptó participar voluntariamente mediante validación electrónica en el formulario, autorizando el uso exclusivo de las estimaciones proporcionadas para fines académicos e investigativos del presente Proyecto de Grado, manteniendo la estricta confidencialidad de la arquitectura y datos sensibles de la empresa.

Datos del Entrevistado:

Cargo: Ingeniero Especialista en Ciberseguridad (SOC).

Fecha de aplicación: 22 de septiembre de 2026

CUESTIONARIO Y RESPUESTAS

1. Considerando la escala de la red, ¿cuál es el volumen estimado de registros (logs) de seguridad que el SOC debe procesar e inspeccionar diariamente?

Respuesta: Entre 10 y 100 millones de eventos.

2. De la totalidad de alertas de seguridad generadas por los sistemas IDS/DLP tradicionales actuales, ¿qué porcentaje estima que corresponden a Falsos Positivos (FPR)?

Respuesta: Más del 75%.

3. ¿Qué porcentaje del tiempo de la jornada laboral de los analistas del SOC se destina exclusivamente a la revisión manual y depuración de estas alertas irrelevantes?

Respuesta: Más del 60%.

4. Frente a ataques sigilosos orientados a la exfiltración de datos, ¿cuál es el Tiempo Medio de Detección histórico estimado con las herramientas basadas en firmas?

Respuesta: Meses (Más de 60 días).

5. ¿Qué porcentaje del tráfico analizado actualmente se encuentra cifrado, limitando la visibilidad de las herramientas de inspección profunda (DPI) heredadas?

Respuesta: Entre el 30% y el 60%.

6. ¿Cuál es la latencia promedio desde que se registra un evento de red anómalo en los dispositivos de borde hasta que la alerta es visible y procesable en el panel del SOC?

Respuesta: Más de 1 minuto.

7. En una escala del 1 al 5 (donde 1 es deficiente y 5 es óptimo), ¿cómo calificaría la capacidad de las reglas estáticas actuales para detectar técnicas de evasión dinámicas (ej. DNS Tunneling)?

Respuesta: 2

8. Para que un nuevo sistema de detección sea considerado un éxito operativo en el SOC, ¿qué porcentaje mínimo de reducción de Falsos Positivos debería alcanzar?

Respuesta: Reducción del 40% al 60%.

9. En términos de rendimiento computacional, ¿cuál debería ser el tiempo máximo de procesamiento aceptable por cada registro para evitar cuellos de botella en un motor de detección asíncrono?

Respuesta: < 50 milisegundos.

10. ¿Cuál es el principal impacto negativo de mantener el esquema reactivo actual frente a un incidente de fuga masiva de datos?

Respuesta: Daño reputacional y pérdida de confianza del cliente corporativo.

ANEXOS

ANEXO A EVIDENCIA DE LA ESCALA OPERATIVA E INFRAESTRUCTURA

Documento fuente: Millicom International Cellular S.A. – Annual Report 2024.

Sección de referencia: *Operational Highlights* / *About Millicom*.

Extracto:

"As of December 31, 2024, we provided services to 41.5 million mobile customers and 4.5 million customer relationships with a subscription to at least one of our fixed services."

Esta cifra oficial certifica que el universo de tráfico de red y registros (logs) que sustenta la metodología de este proyecto (estimado en 1.500 millones de eventos digitales) es proporcional a la envergadura de la infraestructura de telecomunicaciones descrita en los estados operativos de la compañía.